

RG660MK 智能音箱优化设计

本地快速响应 + 实时联网查询 + Hermes 复杂问题处理

版本 V1.0 | 2026-09-14

目标平台	RG660MK / OpenWrt 智能音箱
核心目标	简单问题立即回复；天气类联网查询；复杂问题调用 Hermes
30 秒规则	30 秒仍无最终结果时，先播报“请稍等。”
60 秒规则	60 秒仍无结果时终止本轮并播报“我还没有学会这个问题。”
连续对话	每轮严格隔离，禁止旧答案、旧意图、迟到结果串入下一轮
实施对象	Claude Code / Hermes / 本地研发人员

用途：作为后续代码优化、联调、验收和问题定位的统一设计基线。

1. 背景与优化目标

当前 RG660MK 智能音箱已经具备随时唤醒和连续对话能力，但实际测试暴露出意图路由、短语音处理和多轮状态隔离问题。例如：询问天气或相对论时错误回答“今天星期一”；询问“1+1 等于几”或“打开灯”时反复提示“请再说一下，我没听清”。

本次优化不是简单增加一个大模型，而是建立一套确定性的“本地快速处理 + 联网实时服务 + Hermes 复杂处理”分层架构，使语音交互既快、又稳定、又能处理复杂问题。

1.1 产品级目标

- 简单、确定性问题由本机直接回答或执行，不经过 Hermes，目标为 1~2 秒内开始回复。
- 天气等实时信息通过互联网查询，答案必须来自实时数据而不是模型常识猜测。
- 知识解释、分析、复杂推理和开放式问题交给 Hermes 处理。
- 任何单轮请求达到 30 秒仍无最终结果时，必须先播报“请稍等。”，但后台继续处理。
- 任何单轮请求达到 60 秒仍无结果时，必须取消该轮任务并播报“我还没有学会这个问题。”。
- 连续对话必须做到每轮独立，旧 ASR 文本、旧意图、旧 TTS 队列和迟到的 Hermes 响应不得污染当前轮。

1.2 非目标

- 不要求所有问题都由 Hermes 判断或处理。
- 不允许为了“智能”而牺牲基础命令的响应速度和确定性。
- 不允许用固定缓存答案冒充实时天气。
- 不允许 60 秒以后再播放该轮迟到结果。

2. 总体架构

建议将当前智能音箱软件重构为明确的流水线，每轮请求分配唯一 turn_id，并贯穿 Wake、VAD、ASR、Router、Handler、TTS 全链路。

Wake Word → VAD/录音 → ASR → Intent Router → {Local / Weather-Web / Hermes} → Response Manager → TTS

2.1 三层处理模型

层级	典型请求	处理器	是否联网	期望行为
L0 本地快速	时间、日期、星期、基础算术、音量、播放控制、开关灯	Local Handler	否/局域网	立即执行或回答
L1 实时联网	天气、气温、降雨、空气质量等	Weather/Web Handler	是	查询实时服务后回答
L2 复杂问题	相对论、技术解释、分析、推理、开放式知识问答	Hermes Handler	是/按部署	由 Hermes 生成简洁口语答案

2.2 路由原则

Router 必须是本地、快速、确定性的模块，不能先调用 Hermes 再由 Hermes 决定是否调用自己。建议采用“强规则优先 + 兜底 Hermes”的策略。

```
DEVICE_CONTROL > WEATHER/REALTIME > LOCAL_DATE_TIME > LOCAL_CALCULATOR > HERMES
```

这里的优先级非常关键。例如“今天上海什么天气”同时包含“今天”和“天气”，必须优先命中 WEATHER，而不能因为“今天”被误判成日期查询。

3. Intent Router 详细设计

3.1 本地快速处理

- 日期/星期：今天星期几、今天几号、明天星期几。
- 时间：现在几点、北京时间几点。
- 基础计算：1+1、 23×7 、100 除以 4 等确定性算术。
- 设备控制：打开灯、关闭灯、调亮一点、音量 50%、暂停播放等。
- 设备状态：灯是不是开着、当前音量、网络是否连接等。

基础计算应使用本地安全表达式解析器或专用 calculator，不允许直接 eval 用户输入。设备控制应调用明确的 Matter/本地控制接口，并返回执行结果。

3.2 天气和实时信息处理

- 识别关键词：天气、气温、多少度、降雨、下雨、下雪、空气质量、天气预报等。
- 抽取城市/地点和时间范围，例如“上海”“今天”“明天”“这周末”。
- 调用联网天气服务，设置单独的网络超时和错误处理。
- 如果地点缺失，可使用用户配置的默认城市；如默认城市未配置，再询问用户地点。
- 天气答案保持口语化，优先回答温度、天气现象、降水和必要的出行提醒。

3.3 Hermes 复杂问题处理

以下类型默认进入 Hermes：概念解释、原因分析、比较、推理、技术问题、知识问答、开放式问题、总结和需要多步思考的任务。

示例：

“相对论是怎么回事？” → HERMES

“为什么天空是蓝色的？” → HERMES

“5G SA 和 NSA 有什么区别？” → HERMES

Hermes 的系统提示应明确这是语音助手场景：默认给出简洁、口语化、可朗读的答案；普通问题优先控制在约 100~300 个汉字，除非用户明确要求详细说明。

4. 30 秒 / 60 秒双超时机制

超时逻辑必须由最外层 Conversation Manager 统一管理，而不是分散在 Weather Handler、Hermes Handler 或 TTS 模块内部。计时起点建议定义为 ASR 得到最终文本并开始处理请求的时刻。

时间	系统动作	是否继续后台处理	用户体验
0~29.999 秒	正常等待处理结果	是	有结果即直接播报
达到 30 秒	仅一次播报“请稍等。”	是	告知用户系统仍在处理
30~59.999 秒	继续等待同一 turn_id 的结果	是	结果到达即播报
达到 60 秒	取消/标记该轮失效，播报“我还没有学会这个问题。”	否	本轮强制结束

4.1 必须满足的边界条件

- “请稍等。”只允许在同一轮播报一次。
- 30 秒提示不能把当前 turn 标记为完成。
- 60 秒以后，该轮任何迟到结果都必须丢弃，不能再进入 TTS。
- 如果用户在等待期间主动发起新一轮对话，应按照产品策略取消旧轮或并发隔离；推荐智能音箱采用“新问题优先，取消旧轮”。
- 取消 Hermes 请求失败时，也要至少通过 turn_id 校验阻止迟到结果播放。

```
if response.turn_id != current_turn_id or turn.expired:  
    discard(response)
```

5. 连续对话状态隔离与防串话设计

当前“相对论”仍回答“今天星期一”的现象，高度符合旧 ASR/旧意图/旧 TTS 缓存未清理或异步结果错位。优化后必须把 turn_id 作为核心隔离机制。

5.1 每轮必须重置的状态

```
current_text = ""
current_intent = None
current_response = ""
wait_prompt_played = False
expired = False
audio_buffer.clear()
```

5.2 全链路日志字段

```
[TURN=1042] WAKE=OK
[TURN=1042] AUDIO duration_ms=2360 sr=16000 channels=1
[TURN=1042] ASR_TEXT="今天上海什么天气"
[TURN=1042] ROUTER intent=WEATHER
[TURN=1042] HANDLER weather location=上海 date=今天
[TURN=1042] RESPONSE="上海今天……"
[TURN=1042] TTS_START
[TURN=1042] TTS_DONE
```

5.3 迟到结果处理

所有异步回调都必须携带 turn_id。Response Manager 在进入 TTS 前再次校验 turn_id、expired、cancelled 三个状态。任何不匹配结果一律记录并丢弃。

6. ASR / VAD 稳定性优化

“1+1 等于几”和“打开灯”反复提示没听清，说明短语音场景仍需专项优化。该问题与路由设计并行处理，不应被 Hermes 掩盖。

- 确认 ASR 输入音频格式与模型要求一致，建议统一为 PCM S16LE、16 kHz、mono。
- 唤醒后保留 300~500 ms pre-roll，避免用户紧接唤醒词说话时开头被截断。
- 合理设置最短有效语音时长，建议初始值 300~500 ms。
- 尾部静音判定建议初始值 800~1200 ms，避免短命令过早截断。
- 每轮记录音频时长、字节数、VAD 起止点和 ASR 文本；必要时保留调试 WAV。
- ASR 失败必须将 current_text 清空，禁止沿用上一轮识别结果。

上述参数是联调初值，最终应依据 RG660MK 麦克风、AEC/降噪链路和现场噪声实际测量调整。

7. 推荐状态机与伪代码

```
on_asr_final(text):
    turn = new_turn(text)
    route = router.classify(text)
    future = dispatch(route, text, turn.id)
```

```

while not future.done():
    elapsed = now() - turn.start

    if elapsed >= 30 and not turn.wait_prompt_played:
        tts.say("请稍等。")
        turn.wait_prompt_played = True

    if elapsed >= 60:
        turn.expired = True
        future.cancel()
        tts.say("我还没有学会这个问题。")
        finish(turn)
        return

    sleep(short_interval)

result = future.result()
if turn.expired or turn.id != current_turn_id:
    discard(result)
    return

tts.say(result)
finish(turn)

```

实际实现建议使用异步事件/定时器，不建议用阻塞 while 循环；伪代码只用于表达状态逻辑。

8. 异常与降级策略

异常	推荐处理	禁止行为
ASR 空结果	立即提示“请再说一下，我没听清。”并结束本轮	复用上一轮 ASR_TEXT
天气网络失败	简短提示暂时无法获取天气	用模型猜当前天气
Hermes 调用失败	若未超时则返回简短失败提示；到 60 秒按统一规则结束	无限重试
设备控制失败	返回“打开失败”并记录设备错误码	口头说“已打开”但实际没执行
TTS 队列有旧结果	按 turn_id 清理/丢弃	继续播放旧答案
用户发起新问题	推荐取消旧轮并切换到新 turn	让两个回答交叉播放

9. 验收测试设计

下面测试必须逐条执行，并保存全链路日志。所有测试至少连续执行 5 轮，以验证连续对话状态不会串话。

编号	测试语句	期望路由	通过标准
T01	1+1 等于几？	LOCAL_CALCULATOR	快速回答“2”，不得进入 Hermes
T02	今天星期几？	LOCAL_DATE_TIME	正确回答当前星期
T03	今天上海什么天气？	WEATHER	联网获取上海实时天气；不得回答星期
T04	北京明天会下雨吗？	WEATHER	联网天气预报
T05	相对论是怎么回事？	HERMES	给出相对论解释，不得复用上一轮答案
T06	给我把灯打开。	DEVICE_CONTROL	执行设备控制并反馈结果
T07	模拟 Hermes 35 秒返回	HERMES	30 秒说“请稍等。”，35 秒正常回答
T08	模拟 Hermes 70 秒返回	HERMES	30 秒提示等待；60 秒说未学会；70 秒迟到结果不得播放
T09	连续问天气→相对论→1+1	三类路由	每轮答案与 turn_id 一致，无串话
T10	极短口令“开灯”	DEVICE_CONTROL	ASR 能稳定得到有效文本并执行

10. Claude Code / Hermes 实施建议

10.1 第一阶段：只加观测，不改业务逻辑

1. 定位 Wake、VAD、ASR、Router、Weather、Hermes、TTS 的真实源码入口。
2. 增加 turn_id，并打印完整链路日志。
3. 验证当前错误回答究竟发生在 ASR、Router、Handler 还是 TTS 队列。
4. 保存一组基线测试日志，作为修改前证据。

10.2 第二阶段：重构路由和状态管理

5. 实现 Router 优先级：DEVICE_CONTROL > WEATHER > LOCAL_DATE_TIME > LOCAL_CALCULATOR > HERMES。
6. 每轮重置状态，所有异步任务携带 turn_id。

7. 实现 Local Handler 和 Weather Handler。
8. 将其他复杂问题统一兜底到 Hermes。

10.3 第三阶段：超时与并发控制

9. 统一实现 30 秒提示和 60 秒强制结束。
10. 实现 cancel/expired 机制和迟到结果丢弃。
11. 处理用户在等待过程中发起新问题的抢占逻辑。

10.4 第四阶段：ASR/VAD 专项调优

12. 针对“1+1”“开灯”等短语音测试录音切片。
13. 核对采样率、声道、位宽、pre-roll、min_speech、silence_timeout。
14. 在安静和有背景噪声场景分别做重复性测试。

11. 最终验收标准

- 简单问题和设备控制不依赖 Hermes，平均体验为立即响应。
- 天气类问题能正确识别地点和时间，并从互联网获得实时结果。
- 复杂问题稳定进入 Hermes，回答内容与当前问题一致。
- 任何请求 30 秒无结果必定播报一次“请稍等。”。
- 任何请求 60 秒无结果必定终止并播报“我还没有学会这个问题。”。
- 60 秒后的迟到结果 100% 不进入 TTS。
- 连续 20 轮混合测试不得出现旧答案复用、旧 intent 复用、跨轮 TTS 串话。
- “1+1 等于几”“开灯”等短命令连续 10 次识别成功率达到可接受水平后再进入正式功能验收。

12. 结论

本优化设计将 RG660MK 智能音箱从“所有请求混在同一路径处理”改造成分层、可预测、可观测的语音助手架构。核心不是增加模型复杂度，而是让确定性任务本地即时完成、实时任务使用联网数据、复杂任务交给 Hermes，并通过 turn_id、30/60 秒超时和严格状态隔离保证连续对话稳定性。

该文档可直接作为后续 Claude Code 代码审查、重构和验收测试的需求基线。