

Hermes Token 用量统计

方案设计与测试结果

2026-09-17 · RG660MK 边缘设备 · deepseek-v4-pro / deepseek-flash

一、目标

统计 Hermes Agent 在本设备的 token 消耗与费用，支持按天、按模型查看，并换算为人民币。

二、方案设计

1) 数据源

Hermes 本地 SQLite 库 /data/hermes/.hermes/state.db，三张关键表：

- ☐ sessions —— 会话级汇总（token 字段、模型、成本）
- ☐ session_model_usage —— 按 模型 / 任务 细分的调用数与 token
- ☐ messages —— 消息时间戳，用于把会话用量按天分摊

2) 计费口径（已核对 Hermes 源码 agent/usage_pricing.py）

- ☐ input_tokens = 缓存未命中的输入量
 - ☐ cache_read_tokens = 缓存命中的输入量
 - ☐ output_tokens = completion_tokens，已包含推理 token
 - ☐ reasoning_tokens = 推理 token，是 output 的子集（不可再相加）
- 用量口径 = input + output；缓存命中单独统计。

3) 按天归属

Hermes 按「会话」记账、不按天记账。本方案以「该会话当天的消息条数」为权重，把会话总用量分摊到每一天：总量精确，单日为估值。

4) 人民币计价

采用 DeepSeek 官方人民币价；高峰时段 = 工作日 9:00-12:00、14:00-18:00，其余时段半价；按每日消息的实际时间分布做峰谷混合估算。

三、测试结果

数据区间 2026-09-10 ~ 2026-09-17 (Hermes state.db 实测, 脚本 token_stats.py 输出)

日期	用量(输入+输出)	缓存命中	费用
09-10	353,164	9,341,445	□6.50
09-11	97,375	3,036,929	□1.48
09-12	2,871	106,364	□0.05
09-13	0	0	□0.00
09-14	41,992	350,076	□0.64
09-15	0	0	□0.00
09-16	143,690	2,644,371	□0.44
09-17	619,756	10,188,396	□1.20
合计	1,258,848	25,667,581	□10.31

四、关键发现

- 1. 推理 token 重复计数修正: 初版把 reasoning 也计入「小计」, 得 129.4 万; 核对源码后确认 output_tokens 已含 reasoning, 故「用量 = input + output」才是正确口径。
- 2. 缓存命中占绝对大头, 而缓存单价仅为未命中的 1/20~1/50, 这是费用极低的主因。
- 3. 模型价差显著: v4-pro 单价约为 flash 的 6~7 倍。

五、结论

本方案可复用于任意时段。2026 年 9 月 10-17 日: 用量 125.9 万 tokens, 缓存命中 2566.8 万, 费用合计 □10.31。

六、附：用量与费用曲线图

