人脸属性识别 · 实施方案 V2

RG660MK AI CPE | 性别 + 年龄段 | 旁路部署，不影响 8099 演示

实测日期 2026-11-06 | 1254 张公开标注数据 | 16 帧真人 ground truth | 8099 三轮 A/B 验证 | commit e2888dc

结论先行

能力	结论	实测依据
性别	交付	13/13 帧正确，置信度 0.956–0.999（本人真实画面，多时段）
年龄段 儿童/青年/中年/老年	交付	5/5 正确：真实 50 岁，全部判"中年"
精确年龄	不对外	系统性高估 **+5.3 岁**（真实 50 → 中位 55.6，范围 47.8–63.6），仅内部算段位
情绪（7 类）	已移除	真实场景最好 **36.2%**，随机猜 14.3%；10 次错 6 次，不具备交付条件

一句话：性别和年龄段可以上，情绪不能上。这不是"再调调参数"能解决的——两个模型、六种融合策略、两种预处理，在 1254 张带标注数据上都验证过了。

13/13	5/5	10–37 ms	0.2 ms
性别正确	年龄段正确	单次耗时	8099 影响

与 V1 的差异（V1 的三处判断被实测推翻）

V1 写法	V2 实测	结论变化
情绪 60–75%（文献值）	真实场景 36.2%，实验室 56.0%	文献值不可直接引用，**功能移除**
年龄 ±5–8 岁	+5.3 岁单向高估，跨度 16 岁	精确值不可靠，**改报段位**
单帧 80–160 ms	本机 10–37 ms 设备端 533–654 ms	架构改为本机推理

方法论教训：V1 里那些数字（60–75%、80–160 ms）都是公开文献或估算值，看起来合理，实际偏差 2–5 倍。**凡是要写进交付物的数字，必须在本环境实测。**

一、实测环境

项目	配置	对方案的影响
设备	RG660MK，OpenWrt 23.05，aarch64，Cortex-A55 ×4 @2.3 GHz	CPU 不适合跑 CNN 推理（现有 load 已 6.4）
设备内存	1.49 GB 总，可用约 530 MB	装不下 VLM（最小需 2 GB）
摄像头	Logitech C270，经 camview 以 libuvc 独占	**绝不能第二个进程打开**，只能读 8090/snapshot
推理机	本机 Ubuntu 22.04，i5-1135G7，onnxruntime 1.16.3	CNN 推理 0.3–20 ms，完全够用
网络	网线直连，192.168.1.212 ↔ 192.168.1.1	snapshot 约 40 KB / 帧，实测 3–4 ms

二、能力边界是怎么测出来的

2.1 真人测试（16 帧，有 ground truth）

测试对象：本人，男，**实际年龄 50**。摄像头正对，室内顶光，距离 50–80 cm。

指标	实测值	说明
性别	**13/13 正确**，置信 0.956–0.999	多时段、多姿态重复采样，全部 male
年龄	中位 **55.6**，范围 47.8–63.6	相对真值 +5.3 岁；单帧最大偏差 +13.6 岁
年龄段	**5/5 正确**（全部"中年"）	阈值修正后（<60 中年 / ⩾60 老年）

> **阈值踩坑记录**：初版把年龄段划成 `<55 中年 / ≥55 老年`，50 岁被判"老年"。这是实现错误，不是模型问题。已改为 `<18 / <40 / <60 / ≥60`。

2.2 为什么年龄只报段位

16 帧原始值：47.8 / 50.1 / 53.8 / 54.0 / 63.6 / 55.0 / 56.1 / 56.1 / 56.4 / 56.4 / 58.7 / 55.0 / 58.1 / 55.6 / 56.6 / 56.5

跨度 **15.8 岁**，16 帧里 13 帧偏高，方向一致 → 系统性偏差而非随机噪声。若报精确值，同一个你在不同时刻会得到 48 岁到 64 岁；但"中年"这个判断稳定成立。

取舍：对外只返回 `age_band`，精确值仅在内部用于算段位，不写入响应。

三、情绪识别为何移除

3.1 两个数据集，同一批模型，结果差 20 个百分点

数据集	性质	ViT-AffectNet	FER+
FER2013（700 张）	实验室摆拍，正面大头照	56.0%	49.6%
RAF-DB（554 张）	**真实场景**，互联网图片	36.2%	19.9%
随机猜 7 类	基准线	14.3%	14.3%
商用 API（参考）	云端	65–80%	—

实验室数据好看，是因为 FER2013 全是正面、居中、光照均匀的大头照。真实场景里换个光照、歪个头，准确率直接掉到 36.2%——**比随机猜好 22 个百分点，但离可用线（70%）差一半**。

3.2 六种融合策略都救不回来

策略	FER2013	RAF-DB	问题

仅 ViT-AffectNet	56.0%	36.2%	几乎不会判 neutral（1%）
仅 FER+	49.6%	19.9%	几乎只会判 neutral（91%）
融合 A（FER+ neutral>0.90 优先）	60.6%	—	实验室最高，真实场景失效
融合 B（FER+ neutral>0.70 优先）	58.4%	—	neutral 保住 85%，其他类被拖累
融合 C（ViT 说 neutral 才用 FER+）	56.0%	—	等于纯 ViT，无改善
融合 D（取最大概率者）	59.7%	28.6%	真实场景**比单模型更差**

> **关键发现**：两个模型的错误在真实场景**不互补**——FER2013 上看起来互补（一个偏 neutral、一个偏负面），是因为那个数据集的 happy/neutral 太典型。换到 RAF-DB，融合反而互相拖累（36.2% → 28.6%）。

3.3 还试过：人脸对齐（负优化）

预处理	RAF-DB 准确率
ArcFace 5 点对齐后喂 ViT	32.0%
bbox 直接裁剪喂 ViT	**39.9%**

该 ViT 在 AffectNet 上训练时的预处理不是 ArcFace 对齐，强行对齐反而 **-7.9 个百分点**。这条也写进结论：对齐不是万能的，要按模型训练时的预处理来。

> **决策**：三项能力（性别/年龄/情绪）里，性别和年龄段实测可靠，情绪在端侧小模型上触到天花板。**移除情绪，只交付前两项**，并在文档与接口里明确标注，不做模糊表述。

四、系统架构



4.1 为什么推理放在本机，而不是设备

试过设备端，六个组合全部失败：

尝试	结果
ncnn 1.0.20261020 / 20241226 / 20231027	load_param/load_model 返回 0，但 `extract()` **必然段错误**（exit 139）
numpy 2.4.6 与降级 1.26.4	同样崩溃，排除 ABI 问题
num_threads=1 + 关 packing + 关 fp16	同样崩溃，排除优化指令集问题
CPU 指令集	Cortex-A55 有 asimddp/asimdhp，不是硬件能力问题

结论：ncnn 的 pybind11 绑定在该 musl 环境有兼容性缺陷，不是参数能解决的。C++ 静态链接路径可行（现有 `face_runner` 就是这么做的），但需交叉编译工具链，周期 1–2 小时。

> **当前代价**：依赖笔记本在线。笔记本关机/断网，该功能不可用。**但这条不影响 8099**——8099 的设备端链路完全独立。

4.2 服务实现

项	值
端口	127.0.0.1:8093（本机 0.0.0.0，设备侧亦可调用）
检测器	YuNet（OpenCV Zoo，228 KB），阈值 0.45，最小人脸 28 px
属性模型	InsightFace genderage（1.3 MB，96×96 输入）
耗时	10–37 ms（中位约 15 ms）
内存	RSS 85 MB，空闲 CPU ≈ 0
接口	`POST /vision/attribute`、`GET /health`、`GET /metrics`
控制	`~/attrctl {start|stop|restart|status|health|bench|log}`
自启	crontab `@reboot`（用户级，无需 sudo）

4.3 模型预处理（踩过的两个坑）

> **坑 1：模型内置归一化，外面不能再归一化。**
> `genderage.onnx` 图里自带 `Sub(127.5) → Mul(1/128)`。若外面再做一次 `(x−127.5)/128`，输入被压成极小值，**随机噪声、纯灰图、真人脸会输出完全相同的结果**（female 0.609 / 35.1 岁）。必须传**原始 0–255**。

> **坑 2：必须 RGB，不能用 BGR。**
> cv2 默认读 BGR。实测同一张女性人像：BGR → male（错），RGB → female 0.973（对）。

五、对 8099 的影响

5.1 物理隔离（三层）

隔离维度	做法
CPU	推理 100% 在本机 i5，**RG660MK 的 CPU 占用为 0**
摄像头	只读 `8090/snapshot`；**绝不打开 /dev/video 或 libuvc 设备**（camview 独占，抢会直接黑屏）
服务	独立进程、独立端口 8093；未修改 aicpe-board / camview / 8099 任何文件

5.2 三轮交替 A/B 实测

方法：停服务测 8 次 → 启服务测 8 次 → 重复 3 轮，消除设备负载随时间漂移的影响。

轮次	服务停止（中位）	服务运行（中位）	差
第 1 轮	23.7 ms	25.3 ms	+1.6
第 2 轮	24.9 ms	17.4 ms	−7.5
第 3 轮	18.2 ms	24.9 ms	+6.7
均值	**22.3 ms**	**22.5 ms**	**+0.2**

差异 **0.2 ms**，且方向来回跳（第 2 轮运行反而更快）→ 说明是设备自身在 load 6.4 下的抖动，不是服务引入的。

5.3 40 次连续推理压测

指标	结果
8099 响应中位（推理期间）	17.1 ms
相对无推理基线	−5.1 ms（噪声方向）
8099 请求失败次数	**0**
属性服务自身耗时中位	17 ms

> **结论**：8099 的响应时间在属性服务启停、40 次连续推理期间均无可测量劣化。**唯一真实的威胁是抢摄像头**——已从架构上规避（只读 HTTP 快照）。

5.4 部署与回滚

```
# 启动 / 状态 / 压测
~/attrctl start
~/attrctl status
~/attrctl bench 40

# 回滚（10 秒内，零残留）
~/attrctl stop
crontab -l | grep -v "@reboot.*attrctl" | crontab -
```

回滚后 8099 完全回到部署前状态；服务文件留在 `~/Documents/RG660MK人脸属性/`，不删也不影响任何现有服务。

六、已知限制

限制	说明与影响
人脸小于 28 px	直接跳过。站在 1.5 m 外可能检不到，建议 50–80 cm
侧脸 > 45°	性别判定不稳，年龄波动更大
年龄系统性高估	本环境 +5.3 岁。不同人群（年轻人/女性）偏差方向可能不同，未验证
依赖笔记本在线	关机/断网即不可用。纯端侧需交叉编译 C++ runner
多人场景	返回数组，按人脸面积降序；未做跟踪与去重

七、后续可做（按性价比排序）

#	事项	成本	收益
1	接 8099 演示页按钮	30 分钟	点一下出结果，演示效果直接可见
2	多场景准确率补测	1 小时	补女性/年轻人样本，验证偏差方向是否一致
3	设备端 C++ runner	1–2 小时	脱离笔记本，纯端侧；需交叉编译 ncnn
4	情绪改用云端 API	—	可达 70–80%，但人脸出公网，与端侧定位冲突

> **推荐顺序 1 → 2 → 3**。第 4 项不建议：一旦人脸出公网，"端侧 AI"的产品叙事就不成立了。

八、可溯源清单

数据	来源
性别 13/13、年龄 16 帧、年龄段 5/5	本人真实画面实测，2026-11-06，连续采样
FER2013 700 张（每类 100）	`hf-mirror.com/datasets/Jeneral/fer-2013`
RAF-DB 554 张（每类约 80）	`hf-mirror.com/datasets/elipaluma/RAF-DB_Kaggle`（test 3068 张）
8099 三轮 A/B、40 次压测	`python3 attr_service_pc.py --bench 40` 可复现
全部原始数据与脚本	GitHub `JedyYing/RG660MK-EU-AI-CPE` → `face-attr/bench/results.md`