RG660MK 人脸属性识别设计文档

在现有 AI CPE 视觉链路上扩展「性别 / 年龄 / 情绪」识别能力

版本 V1.0 | 2026-11-06 | 应金栋 Jedy Ying | 硬件 RG660MK（MediaTek evb6988 / MT6990 + MT7992） | 软件 OpenWrt 23.05 · aarch64

一、目标与约束

目标：在 RG660MK 现有摄像头链路上，对画面中出现的人脸实时输出三项属性——**性别**（男/女）、**年龄**（分段或数值）、**情绪**（中性/高兴/惊讶/难过/生气/厌恶/恐惧），并接入现有演示看板与语音播报。

硬约束（实测基线，非估算）

项目	实测值	对设计的含义
CPU	4 核 aarch64，最高 2.3 GHz	可跑 MobileNet 级模型，不能跑 ResNet/大 ViT
内存	1.49 GB 总 / 约 800 MB 已用	模型常驻内存预算 ≤ 150 MB
系统盘	overlay 21.4 MB（已用 248 KB）	模型必须放 /data，不能进 overlay
数据盘	/data 2.7 GB（df：已用 2.1 GB，可用 421 MB，84%）	新增模型 + 依赖须 ≤ 100 MB
NPU / 加速器	无可用 NPU 驱动（HailoRT 仅接口占位）	纯 CPU 推理，靠模型轻量化
摄像头	Logitech C270，libuvc 用户态直采	无 /dev/video*，取帧只能走 camview:8090/snapshot
当前负载	load average 5.2（5 分钟）	属高负载，新增推理必须限频、可关停

关键约束：设备当前 load average 已达 5.2（已有语音、演示看板、camview、camav、cloudflared 常驻），CPU 余量有限。因此本方案默认**单帧低频推理**（1–2 FPS）+ **按需触发**，不做连续高帧率视频流分析。

二、现状基线：我们已经有的，不用重造

现场排查确认，RG660MK 上已具备一条完整的人脸推理链路，本次设计**复用而非重建**：

已有组件	位置 / 形式	能力
NCNN 人脸运行时	`/data/ai_cpe/demo/ai_runtime/face/face_runner`（6.1 MB aarch64 二进制）	进程内完成检测 + 特征提取，JSON 输入输出
人脸检测模型	`mnet.25-opt.bin/.param`（834 KB）	RetinaFace 轻量版，输出人脸框 + 5 关键点
人脸特征模型	`mobilefacenet.bin/.param`（3.9 MB）	128/512 维特征，用于身份比对
目标检测模型	`ai_models/yolov8n/model.ncnn.*`（12.1 MB）	YOLOv8n ncnn，用于人形/物体检测
姿态模型	`ai_models/yolov8n-pose`	人体关键点（坐姿检测已在用）
视觉服务	`ai_service.py` → 127.0.0.1:8765	提供 `/vision/face`；spawn runner 子进程，stdin/stdout 走 JSON
取帧通道	`camview --port 8090` → `/snapshot`	libuvc 直采 C270，输出 ~40 KB JPEG（实测 39.9 KB）
人脸库	`demo/data/face-gallery.json`	已注册身份，支持多人
语音链路	sherpa-onnx ASR + piper TTS，ws:6006	属性结果可直接进播报

> **结论**：本次只需新增 **2 个轻量 NCNN 模型**（性别年龄 + 情绪）和 **1 个属性分支**，不引入 ONNX Runtime / PyTorch / OpenCV 等新框架——设备上这些一个都没有（实测 `onnxruntime/tflite/ncnn-python/cv2/torch` 全部未安装），新增框架会直接撞上 overlay 21 MB + /data 剩余 421 MB 的硬限制。

复用的数据流（现状）



三、方案选型：三条路，为什么选 A

维度	A · 设备端全本地	B · 设备抓帧 + 本机/服务器推理	C · 云端 API
实现方式	新增 NCNN 模型，跑在 face_runner 同一框架内	设备 POST 图片到 PC（i5-1135G7 + Iris Xe，已有 onnxruntime 1.16.3 + cv2 4.11）	调用百度/腾讯人脸属性接口
隐私	最优 人脸不出设备	可控 只在局域网内传输	有风险 人脸出公网
延迟	约 80–150 ms/帧（估算，待实测）	约 40–80 ms（PC 算力强）+ 局域网 5–15 ms	200–600 ms（受运营商网络影响）
断网可用	可以	可以（同一局域网）	不行
新增依赖	2 个模型文件（合计 < 10 MB）	设备端零新增；PC 端需常驻服务	API Key + 计费 + 合规评估
设备负载压力	中 当前 load 5.2，需限频	低 只做编码上传	低
成本	零	零（用现有 PC）	按调用计费

推荐：A 为主，B 作为可选加速档
理由：① 用户产品方向是端侧 AI Home Hub，属性识别属隐私敏感能力，必须默认不出设备；② 设备已有 NCNN 链路，A 的边际成本只有两个模型文件；③ B 复用同一套 HTTP 契约（只换 base URL），可作为「多脸 / 高帧率」场景的降级方案，不需要改上层。
C 不采纳：人脸出公网 + 按次计费，与端侧定位冲突，仅保留为将来跨设备扩展的参考。

四、系统架构（推荐方案 A）



分层说明

层	职责	落地方式
采集层	按需取单帧，不做连续流	HTTP GET `127.0.0.1:8090/snapshot`，超时 5 s
检测层	人脸框 + 关键点，过滤小脸/侧脸	复用 `face_runner` 的检测分支，阈值可配
属性层	性别年龄 + 情绪两路分类	新增 `attr_runner`（NCNN，与 face_runner 同编译方式）或扩展 face_runner 增加 op
服务层	对外 HTTP，鉴权、限流、超时	在 `ai_service.py` 增加 `/vision/attribute`（复用现有 token + 超时机制）
呈现层	看板卡片 / 画面叠加 / 语音	8099 演示页新增「人脸属性」面板；TTS 走现有 piper

为什么属性层单独一个 runner，而不是塞进 face_runner：face_runner 当前只输出身份特征，改动它需要重新编译并回归已验证的人脸识别链路（风险高）；新开 `attr_runner` 沿用同一 NCNN 运行时和 JSON 协议，字节级隔离，出问题不影响现有人脸识别——符合「先找最小回归点」的调试原则。

五、模型选型与性能预算

环节	模型	输入	体积	预估耗时	说明
人脸检测	mnet.25-opt（RetinaFace）	640×480	834 KB	60–120 ms	已有，复用；设备主要耗时项
对齐裁剪	仿射变换（C）	112×112	—	< 5 ms	用检测出的 5 关键点
性别 + 年龄	InsightFace genderage（转 ncnn）	96×96 RGB	≈ 1.6 MB	8–18 ms	性别 2 类 + 年龄回归；输出年龄 ±5 岁
情绪	mini-Xception / MobileNetV2-emotion（转 ncnn）	64×64 灰度	2–5 MB	6–15 ms	7 类情绪；FER+ 预训练权重可迁移
单帧合计	新增模型合计 ⩽ 7 MB			**80–160 ms**	单脸场景；多脸按人脸数线性叠加

耗时为依据设备 CPU（4×2.3 GHz aarch64、NCNN、无 NEON 优化差异校正）的**工程估算**，须在实施第 1 阶段用真实 snapshot 实测校准；验收以实测为准。

1–2 FPS	< 7 MB	⩽ 150 MB	0
默认推理频率（限频保护负载）	新增模型总体积	推理常驻内存上限	新增框架依赖

精度预期与边界（必须在文档里说清楚）

- **性别**：正脸、光照正常时准确率约 95%；侧脸 / 遮挡 / 强逆光明显下降，输出需带置信度。
- **年龄**：模型输出的是**估计值**，实测误差通常 ±5–8 岁；对外统一用分段（儿童 / 青年 / 中年 / 老年），不承诺精确岁数。
- **情绪**：7 类离散标签，真实场景准确率约 60–75%（FER 系列模型通病）；**只能是参考，不能用于医疗或心理判断**，演示口径须写明。
- **不适用**：戴口罩、墨镜、背影、多人远距离小脸（< 40 px）不输出结果，直接返回空。

六、接口设计

新增接口（与现有 `/vision/face` 同风格，同一 token 鉴权）：

项	定义
方法 / 路径	`POST http://127.0.0.1:8765/vision/attribute`
请求头	`X-Api-Token: <demo/data/api-token>`、`Content-Type: application/json`
请求体	`{"image":"/tmp/snap.jpg","want":["gender","age","emotion"],"min_face_px":40}`

响应体	`{"ok":true,"faces":[{"bbox":[x,y,w,h],"gender":"male","gender_score":0.97,"age":31,"age_band":"青年","emotion":"happy","emotion_score":0.78}],"elapsed_ms":132}`
错误码	`UNAUTHORIZED` / `INVALID_ARGUMENT` / `RUNTIME_UNAVAILABLE` / `TIMEOUT`（沿用 ai_service 现有错误体系）
超时	单次 ⩽ 8 s；连续失败 3 次自动降级（返回空结果，不阻塞看板）

中文播报文本（供 TTS，一行）：

`识别到 1 个人：青年男性，看起来心情不错` ／ `识别到 2 个人（1 男 1 女）` ／ `没有检测到可分析的人脸`

七、实施计划（4 阶段，每阶段有验收物）

阶段	内容	验收标准（实测）	风险控制
P1 1–2 天	模型准备：下载 genderage / emotion 模型并转 ncnn；放 `/data/ai_cpe/demo/ai_models/attr/`	模型加载成功；单模型在设备上跑通一次推理，记录实测耗时	模型体积超 20 MB 即回退备选模型
P2 2–3 天	写 `attr_runner`（C/C++，NCNN），JSON stdin/stdout 协议对齐 face_runner	同一张 snapshot 连续 10 次输出稳定；`ps` 无内存泄漏增长	与 face_runner 完全隔离，不改现有二进制
P3 1–2 天	ai_service 增加 `/vision/attribute`；接 8099 演示看板卡片 + TTS 播报	端到端：点一次 → 看板出属性卡片 → 语音播报；单次端到端 ⩽ 1.5 s	限流 1 FPS；连续失败 3 次自动关闭该面板
P4 1 天	准确率抽测 + 负载回归	⩾ 30 张标注样本：性别 ⩾ 90%、年龄分段 ⩾ 70%、情绪 ⩾ 60%；设备 load 增量 ⩽ 1.0	不达标只影响该面板，不影响主演示

八、风险与回滚

风险	影响	应对
设备 CPU 余量不足（当前 load 5.2）	属性推理抢 CPU，拖慢语音/看板	默认 1 FPS + nice 降权；提供 `/vision/attribute?off=1` 一键停用；必要时改走方案 B（PC 推理）
/data 剩余仅 421 MB	模型 + 日志放大后写满	模型总量卡 ⩽ 20 MB；日志按日轮转，保留 3 天
年龄/情绪准确率不达预期	演示效果差，被质疑	对外统一用分段 + 置信度；看板标注「AI 估计值」；准备 20 张标准样本做现场对比演示
摄像头被 camview 独占	取帧失败	只用 `8090/snapshot`，绝不直接打开 USB 设备（这是已验证的唯一安全取帧方式）
隐私合规	人脸数据外流质疑	默认全本地；不落盘原始人脸（只留统计）；提供「属性识别关闭」开关

回滚方案（一键、秒级）：删除 `/data/ai_cpe/demo/ai_models/attr/` 目录 + 停 `attr_runner` 即可，**不改动任何现有文件**。ai_service 的 `/vision/attribute` 在模型缺失时返回 `RUNTIME_UNAVAILABLE`，其余功能（人脸识别、YOLO 检测、语音、演示看板）完全不受影响——这是本方案最大的工程优势。

九、结论

当前硬件**足够**支撑性别/年龄/情绪的端侧识别，前提是：**复用已有 NCNN 链路、只加两个轻量模型、默认低频按需推理**。真正需要投入的不是算力，而是两件事——**模型转换（ONNX → ncnn）**和**准确率的诚实口径**。按 P1–P4 推进，最快 5–7 个工作日可交付可演示的闭环。

附录：上线后快速验证命令

1. 抓一帧验证摄像头

```
curl -s -m 5 http://127.0.0.1:8090/snapshot -o /tmp/s.jpg && ls -l /tmp/s.jpg
```

正常约 40 KB；返回 0 字节说明 camview 异常。

2. 单独验证属性接口

```
TOK=$(cat /data/ai_cpe/demo/data/api-token)
curl -s -m 8 -X POST http://127.0.0.1:8765/vision/attribute \
  -H "X-Api-Token: $TOK" -H "Content-Type: application/json" \
  -d '{"image":"/tmp/s.jpg","want":["gender","age","emotion"]}'
```

3. 看推理耗时与错误

```
logread | grep -i attribute | tail -20
```

关注 elapsed_ms 与 TIMEOUT / RUNTIME_UNAVAILABLE。

4. 确认没压垮设备

```
uptime; top -b -n 1 | head -5
```

上线前 load≈5.2 为基线，增量应 ⩽ 1.0。

5. 一键停用（回滚）

```
rm -rf /data/ai_cpe/demo/ai_models/attr
```

接口立即返回 RUNTIME_UNAVAILABLE，其余功能不受影响。

本 PDF 由 `~/Documents/RG660MK人脸属性/设计文档_V1.html` 渲染生成，可改后重出。
所有硬件/软件基线数据来自 2026-11-06 在设备上的现场实测（uname、free、df、ls、进程与端口探测）；推理耗时为工程估算，已在文中标注，P1 阶段实测校准。