DeepSeek Harness 从 MT200 移植至 Windows ThinkPad 部署设计文档

v1.0 · Windows 11 x64 · 本地离线 Agent · OpenAI 兼容推理接口

迁移目标

把 MT200 上已经验证成功的 DeepSeek Harness + 本地模型 + 工具调用闭环，迁移到 Windows ThinkPad。首要目标是“先完整复现闭环，再按 ThinkPad 实际 GPU/CPU 做加速”，而不是继续携带 MT200 的 QNN/Genie/FastRPC 专属问题。

来源基线	MT200 本地 DeepSeek Harness 部署报告（2026-10-23）
目标平台	Windows ThinkPad，推荐 Windows 11 x64
推荐主路径	Windows 原生 dsh + Windows llama-server
备选路径	WSL2 Ubuntu（仅在旧脚本强依赖 Bash/Linux 时使用）
作者	ChatGPT

日期：2026-10-23

1. 结论与推荐方案

一句话结论

推荐优先使用 Windows 原生方案：DeepSeek Harness 原生运行于 Windows，shell 工具切换为 PowerShell；推理层仍保持 OpenAI 兼容 API，用 Windows 版 llama-server 承载本地 GGUF 模型。这样可以绕开 MT200 上尚未解决的 QNN/Genie/FastRPC，同时最大程度复用现有 Harness 配置与 Agent 工作流。

层	MT200 当前实现	Windows ThinkPad 迁移后
接入层	Web UI，10.42.0.81:3080	Web UI，默认 127.0.0.1:3080
Harness	dsh 0.2.1-rc.2	dsh Windows 原生；首次建议锁版本/保存 lock 信息
Shell 工具	bash	PowerShell 7 / pwsh
推理接口	OpenAI compatible	保持不变
推理引擎	MEIGINE llama-server，CPU -ngl 0	Windows llama-server：CPU / CUDA / Vulkan 按硬件选择
模型	Qwen3-1.7B Q4	先复现同一 GGUF，再升级模型
服务管理	systemd	PowerShell 启动脚本 + Task Scheduler/NSSM（可选）
NPU 专属	QNN/Genie/FastRPC，未打通	不迁移；仅在 ThinkPad 有独立 NPU 且后续有成熟后端时再单独评估

推荐优先级：

1. P0：先在 Windows 原生环境复现 MT200 上已经通过的 “tool_call -> tool_result -> final” 闭环。
2. P1：再根据 ThinkPad 实际显卡选择 CPU、NVIDIA CUDA 或 Vulkan 加速。
3. P2：最后再做开机自启、远程访问、温度/功耗与长期稳定性。

2. MT200 已验证基线与迁移边界

附件部署报告已经证明以下链路可工作，因此移植时应尽量保持这些接口与行为，而不是重新设计 Agent：

- Harness 已接入本地 OpenAI 兼容接口，baseURL 指向本地 llama-server。
- Qwen3-1.7B Q4 可在 CPU 4 线程运行，contextWindow=12288。
- Web UI + Agent + bash 工具调用 + 本地模型已经端到端闭环，真实执行 date 与 df 后能基于 tool_result 生成 final。
- 工具 schema 从 5621 token 裁到 2232 token 后，prefill 和温升显著改善；此优化应保留。
- MT200 的 QNN/Genie/FastRPC 仍卡在 shared memory / memRegister；该故障属于 MT200 NPU 栈，不应作为 Windows 迁移前置条件。

项目	迁移策略	原因
dsh profile / provider 设计	复用逻辑，重新生成 Windows 路径	路径分隔符、shell 工具与权限模型不同
GGUF 模型	优先复制并校验 SHA256	可形成同模型 A/B 基线
llama-server 参数	语义复用，路径/加速参数改写	Windows 可直接运行，GPU 后端不同
systemd unit	不迁移	Windows 无 systemd
bash 工具	替换为 PowerShell 工具	Windows 原生 Harness 使用 PowerShell

		shell stack
QNN/Genie/FastRPC	不迁移	Qualcomm MT200 专属运行栈
IP 10.42.0.81	不保留	ThinkPad 默认 localhost；远程访问另开监听与防火墙

3. Windows 目标架构

```
浏览器 http://127.0.0.1:3080
        |
        v
DeepSeek Harness (dsh web, Windows native)
        |  PowerShell tools / workspace / session
        |  OpenAI-compatible API
        v
llama-server.exe  http://127.0.0.1:8080/v1
        |
        +--> CPU fallback
        +--> NVIDIA CUDA (若 ThinkPad 有 NVIDIA 独显)
        +--> Vulkan (适合部分 Intel/AMD/NVIDIA GPU，需实际验证)
        v
本地 GGUF 模型（第一阶段：复用 Qwen3-1.7B Q4）
```

核心原则
Harness 与推理解耦。dsh 只认 OpenAI 兼容 API；后端从 CPU 换到 CUDA/Vulkan 时，Harness 配置不需要重新设计。

3.1 为什么优先 Windows 原生而不是 WSL2

维度	Windows 原生（推荐）	WSL2（备选）
Harness shell	PowerShell，官方 Windows 路径	Bash，接近 MT200/Linux
本地 Web UI	127.0.0.1:3080，最简单	需处理 WSL 网络/端口
GPU 接入	Windows llama.cpp 后端直接使用	NVIDIA 通常可用，其他 GPU 路径更复杂
脚本兼容	需把 bash 脚本改为 PowerShell	Linux 脚本复用更高
服务管理	Task Scheduler / NSSM	systemd（启用后）
适用场景	ThinkPad 日常演示、交付、用户使用	大量现有 Linux 自动化不可改时

4. 迁移前硬件与系统探测

由于尚未给出 ThinkPad 的具体 CPU/GPU/内存型号，设计文档采用“自动探测后选择后端”的方式，不预设一定存在 NVIDIA GPU。先在 PowerShell 7 中执行：

```
$ErrorActionPreference = "Continue"
Write-Host "=== OS ==="
Get-ComputerInfo | Select-Object WindowsProductName, WindowsVersion, OsBuildNumber
Write-Host "=== CPU ==="
Get-CimInstance Win32_Processor | Select-Object Name, NumberOfCores, NumberOfLogicalProcessors
Write-Host "=== RAM ==="
Get-CimInstance Win32_ComputerSystem | Select-Object @{N='RAM_GB';E={[math]::Round($_.TotalPhysicalMemory/1GB,1)}}
Write-Host "=== GPU ==="
Get-CimInstance Win32_VideoController | Select-Object Name, AdapterRAM, DriverVersion
Write-Host "=== NVIDIA ==="
nvidia-smi 2>$null
Write-Host "=== Toolchain ==="
node -v; npm -v; pwsh -v; git --version
```

检测结果	推理后端建议	第一阶段模型
有 NVIDIA RTX / 专业 NVIDIA GPU	优先 CUDA build	Qwen3-1.7B Q4 -> 7B Q4
无 NVIDIA，但有 Intel/AMD 图形	先 CPU；再 A/B Vulkan	Qwen3-1.7B Q4
仅 CPU 或驱动环境不稳定	CPU fallback	Qwen3-1.7B Q4 / 更小模型
RAM < 16 GB	避免 7B 大 context	1.7B/3B Q4
RAM >= 32 GB	可评估 7B/14B 量化模型	先 7B Q4，按实际吞吐决定

5. Windows 原生部署步骤（推荐主路径）

5.1 创建固定目录

```
New-Item -ItemType Directory -Force C:\AI\dsh, C:\AI\models, C:\AI\logs, C:\AI\scripts | Out-Null
Set-Location C:\AI\dsh
```

5.2 安装基础依赖

```
# 建议管理员 PowerShell 执行安装，日常运行使用普通用户权限
winget install OpenJS.NodeJS.LTS
winget install Git.Git
winget install Microsoft.PowerShell
winget install llama.cpp

# 重新打开 PowerShell 后检查
```

```
node -v
npm -v
pwsh -v
llama-server --help
```

DeepSeek Harness 官方当前推荐通过 npm/npx 启动；llama.cpp 官方提供 Windows 的 winget 安装方式。正式交付前应记录实际版本，避免开发者预览阶段升级造成行为变化。

5.3 准备模型并建立同模型基线

优先复制 MT200 当前验证过的 Qwen3-1.7B Q4 GGUF 到 C:\AI\models，并记录 SHA256。这样 Windows 与 MT200 可以做同模型对照。若原模型文件无法复制，则选取等价 Q4 GGUF，但报告中要明确“不是同一模型文件”。

```
Get-FileHash C:\AI\models\qwen3-1.7b-q4.gguf -Algorithm SHA256
```

5.4 启动 llama-server：CPU 基线

```
llama-server `
  -m C:\AI\models\qwen3-1.7b-q4.gguf `
  -c 12288 `
  -t 4 `
  --host 127.0.0.1 `
  --port 8080
```

先不要做 GPU 优化。首轮目标是验证 API、模型和 Harness 都能工作。若 ThinkPad CPU 核心数较多，可在稳定后再把 -t 调到物理性能核附近做 A/B。

5.5 验证 OpenAI 兼容接口

```
Invoke-RestMethod http://127.0.0.1:8080/v1/models


$body = @{
  model = "qwen3-1.7b"
  messages = @(@{ role="user"; content="只回复 WINDOWS_OK" })
  temperature = 0
} | ConvertTo-Json -Depth 8


Invoke-RestMethod `
  -Uri http://127.0.0.1:8080/v1/chat/completions `
  -Method Post `
  -ContentType "application/json" `
  -Body $body
```

5.6 启动 DeepSeek Harness

```
Set-Location C:\AI\dsh
npx @deepseek-ai/dsh web
```

默认 Web UI 为 http://127.0.0.1:3080。首次迁移建议在一个专用、可回滚的测试 workspace 中运行，不要直接给整个用户目录或敏感目录权限。

5.7 添加本地模型 Provider

字段	建议值
Provider ID	thinkpad-local
类型	Custom model API
Base URL	http://127.0.0.1:8080/v1
API protocol	OpenAI Chat Completions / openai-completions
Model ID	以 /v1/models 返回为准
Context window	先与 llama-server 对齐为 12288；显存/内存不足时再降低

6. Harness 配置迁移策略

不要直接整目录覆盖

MT200 的 profile 内可能包含 Linux 路径、bash 工具和历史 session 固化的 contextWindow。Windows 应新建 profile，然后按字段迁移 provider、模型、工具白名单与 prompt。

配置项	处理方式
provider/baseURL	保持 OpenAI API 语义，地址改为 localhost
contextWindow	新会话重新创建，必须与 Windows llama-server 的 -c 一致
旧会话	只归档，不作为首次验收会话
工具插件	保持“够用最小集”，不要恢复 31 工具全量
bash	迁移成 PowerShell 等价命令
Linux 路径 /home/...	改成 C:\AI\... 或 workspace 相对路径
凭据	不要复制明文；在 Windows 上重新配置
安全权限	首次只授权测试 workspace

6.1 典型 Bash -> PowerShell 映射

Linux/MT200	Windows PowerShell
date	Get-Date
df -h	Get-PSDrive -PSProvider FileSystem
ls -lah	Get-ChildItem -Force
cat file	Get-Content file
grep pattern file	Select-String -Pattern pattern -Path file
journalctl	Get-WinEvent / 应用自身日志
systemctl	Get-Service / Task Scheduler / NSSM

export VAR=value	$env:VAR="value"

7. ThinkPad 推理加速分支

7.1 NVIDIA GPU（优先）

如果 nvidia-smi 正常，建议使用 llama.cpp 的 CUDA 构建/发行包，然后把尽可能多的层卸载到 GPU。具体可用参数应以当前安装包的 --help 为准；首次只改变 GPU offload 一个变量。

```
# 先确认驱动
nvidia-smi


# 查看当前 llama-server 支持参数
llama-server --help | Select-String "gpu|layer|cuda"


# 示例：若当前版本支持 -ngl
llama-server -m C:\AI\models\qwen3-1.7b-q4.gguf -c 12288 -ngl 99 --host 127.0.0.1 --port 8080
```

7.2 Intel / AMD / 无 NVIDIA

先保持 CPU 路径稳定。如果已安装支持 Vulkan 的 llama.cpp 构建，再做 Vulkan A/B；不应为了“用上 GPU”破坏已工作的 CPU fallback。所有 GPU 路径必须用相同 prompt、相同模型、相同 context 做对比。

7.3 不建议第一阶段依赖 ThinkPad NPU

Windows 笔记本可能带 Intel/AMD/Qualcomm NPU，但 DeepSeek Harness 本身并不要求 NPU。第一阶段应优先选择 llama.cpp 已成熟支持的 CPU/CUDA/Vulkan 路径。只有当目标 ThinkPad 的 NPU 有稳定、可维护且能暴露 OpenAI 兼容接口的推理后端时，再把 NPU 作为第三阶段优化。

8. 服务化与一键启动

建议先采用一个 PowerShell 启动脚本统一管理两个进程；稳定后再配置 Task Scheduler 或 NSSM。

```
# C:\AI\scripts\start-dsh.ps1
$ErrorActionPreference = "Stop"
$log = "C:\AI\logs"
New-Item -ItemType Directory -Force $log | Out-Null


# 1) 启动推理服务
$llamaArgs = @(
  "-m", "C:\AI\models\qwen3-1.7b-q4.gguf",
  "-c", "12288",
  "-t", "4",
  "--host", "127.0.0.1",
```

```
  "--port", "8080"
)
Start-Process -FilePath "llama-server.exe" -ArgumentList $llamaArgs `
  -RedirectStandardOutput "$log\llama.out.log" `
  -RedirectStandardError "$log\llama.err.log"

# 2) 等待模型 API
for ($i=0; $i -lt 60; $i++) {
  try {
    Invoke-RestMethod http://127.0.0.1:8080/v1/models -TimeoutSec 2 | Out-Null
    break
  } catch { Start-Sleep -Seconds 1 }
}

# 3) 启动 Harness
Set-Location C:\AI\dsh
npx @deepseek-ai/dsh web --no-open
```

安全建议

默认只监听 127.0.0.1。只有明确需要局域网访问时再改监听地址，并同步配置 Windows Defender Firewall；不要把未做认证的 llama-server 直接暴露到公司或公网网络。

9. 分阶段验收方案

阶段	验收项	通过标准
A. 推理服务	/v1/models + chat completions	HTTP 200；固定 prompt 稳定返回
B. Harness UI	dsh web	127.0.0.1:3080 可访问，无启动报错
C. 本地 Provider	Harness -> llama-server	新会话能完成普通问答
D. 工具闭环	PowerShell 工具调用	tool_call -> tool_result -> final 完整出现
E. 原任务复现	Windows 版 date/磁盘任务	回答必须基于真实命令结果，不允许模型臆测
F. 连续稳定性	连续 20 次同类 Agent 任务	0 崩溃、0 上下文溢出、0 无故工具失败
G. 性能	记录 TTFT/decode/总任务时延	形成 CPU/GPU A/B 表，而非只看 tok/s

9.1 推荐的 Windows 等价验收任务

```
请调用 PowerShell 获取当前日期，并执行：
Get-PSDrive -PSProvider FileSystem
然后用一句中文总结 C: 盘的 Used/Free 情况。
```

```
要求：必须先调用工具，再根据真实 tool_result 回答。
```

该任务对应 MT200 报告里已通过的 date + df -h /data 场景，可以直接验证“迁移后仍然是真工具闭环，而不是模型自己编答案”。

10. 性能与热管理测试

指标	记录方式	目的
Prompt tokens	llama-server 日志	对齐 MT200 2232-token 基线
TTFT / prefill	服务日志或请求计时	衡量 Agent 首次工具调用等待
Decode tok/s	llama-server 日志	比较 CPU/CUDA/Vulkan
Agent 总时延	用户提交 -> final	真正衡量 Harness 体验
CPU/GPU 占用	Task Manager / nvidia-smi	确认加速是否实际生效
RAM/VRAM 峰值	Task Manager / nvidia-smi	判断能否升级 7B
温度/功耗	Lenovo Vantage/HWiNFO 等可用工具	防止笔记本持续满载降频

对照重点

MT200 当前 1.7B Q4 的 CPU decode 约 17 tok/s，prompt 2232 token 的 prefill 约 27.7 s。Windows ThinkPad 迁移后的第一目标不是必须“超过”它，而是先确保同模型、同 prompt、同工具集下稳定闭环；之后再比较性能。

11. 常见故障与处理

现象	优先检查	处理
dsh 启动失败	Node/npm 版本、npx 缓存、网络	记录 npm view engines；必要时锁版本并重新安装
Web UI 400 / context 超限	工具 schema + 新会话 contextWindow	保持精简工具集；删旧测试会话仅做归档，新建会话验证
Harness 找不到模型	/v1/models 与 model id	以服务实际返回 id 为准，不手写猜测
PowerShell 工具失败	执行策略/工作目录/权限	只给测试 workspace；检查 pwsh 与 PATH
llama-server OOM	context、模型量化、GPU offload	先降 context，再降模型；逐项改变量
GPU 不生效	llama.cpp 构建后端/驱动	先确认当前二进制确实含 CUDA/Vulkan 支持
端口冲突	8080/3080 被占用	Get-NetTCPConnection -LocalPort 8080,3080
升级后行为改变	Harness 开发者预览快速迭代	保存版本清单与可回滚环境，不在演示前自动升级

12. 实际迁移执行清单

4. 从 MT200 导出：模型文件 SHA256、dsh 配置截图/字段、精简后的 9 工具列表、关键 system prompt；不要导出明文凭据。
5. 在 ThinkPad 完成 CPU/GPU/RAM 探测并保存 hardware.txt。
6. 安装 Node.js、PowerShell、Git、llama.cpp，记录 versions.txt。
7. 复制/下载 Qwen3-1.7B Q4，校验 SHA256。
8. 启动 CPU llama-server，先独立通过 /v1/models 与 chat completions。
9. 启动 dsh web，新建 Windows profile，创建 thinkpad-local provider。
10. 只挂最小工具集，创建新会话，执行等价 PowerShell 工具闭环。
11. 连续跑 20 次验收；保存 dsh 与 llama-server 日志。
12. 若有 NVIDIA GPU，再切 CUDA；若无，CPU 稳定后再评估 Vulkan。
13. 完成 CPU/GPU A/B 后再决定是否升级 7B。
14. 最后配置一键启动和开机自启，不在调试期过早服务化。

13. 可直接交给 Hermes / Claude Code 执行的迁移指令

```
任务：把当前 MT200 的 DeepSeek Harness 本地 Agent 部署迁移到 Windows ThinkPad。

约束：
1. 先做 Windows 原生路径，不使用 WSL2，除非原生路径出现无法绕过的兼容性问题。
2. 不迁移 QNN / Genie / FastRPC / Hexagon HTP 配置。
3. Harness 与推理层之间保持 OpenAI-compatible API。
4. 第一阶段必须先用 CPU 路径复现闭环，再做 GPU 加速。
5. 第一阶段模型优先复用 MT200 的 Qwen3-1.7B Q4 GGUF，并记录 SHA256。
6. 只允许对 C:\AI\dsh 测试 workspace 执行 Agent 写操作；禁止开放整个 C: 盘写权限。
7. 不复制任何明文 API key 或历史 credential 文件。
8. 不允许一次同时修改模型、context、工具数量和 GPU 后端。

执行：
A. 采集 Windows/CPU/RAM/GPU/Node/npm/pwsh/git 环境信息，输出 C:\AI\logs\preflight.txt。
B. 创建 C:\AI\{dsh,models,logs,scripts}。
C. 安装/验证 llama.cpp Windows 版，启动 CPU llama-server：127.0.0.1:8080。
D. 验证 /v1/models 和 /v1/chat/completions；失败时先修推理服务，禁止进入 Harness 调试。
E. 使用 npx @deepseek-ai/dsh web 启动 Web UI。
F. 新建 Custom model API provider：thinkpad-local -> http://127.0.0.1:8080/v1。
G. 新建会话，禁止复用 MT200 旧会话的 context 固化值。
H. 工具集保持最小化；Windows 使用 PowerShell 工具，不强行恢复 bash。
I. 执行验收任务：调用 Get-Date 与 Get-PSDrive -PSProvider FileSystem，然后基于真实 tool_result 总结 C: 盘。
J. 连续执行 20 轮，记录每轮：PASS/FAIL、总时延、首次 tool_call 时延、模型 prefill、decode tok/s、RAM、GPU/CPU 占用。
```

```
K. CPU 路径 20/20 稳定后，若 nvidia-smi 正常，再启用 CUDA 并重复相同 20 轮；否则保持 CPU baseline，再单独评估 Vulkan。

L. 输出 migration_report.md，明确：版本、硬件、模型 SHA256、配置、失败项、性能对比、下一步是否适合升级 7B。


成功条件：

- dsh Web UI 稳定启动；

- 本地模型完全离线可调用；

- tool_call -> tool_result -> final 闭环成立；

- 连续 20 轮无崩溃、无 context overflow；

- 日志和一键启动脚本可复现。
```

14. 参考与版本边界

本设计以用户提供的《MT200 本地 DeepSeek Harness 部署报告（2026-10-23）》为迁移基线，并结合 DeepSeek Harness 与 llama.cpp 在 2026-10-23 可查到的官方公开说明。DeepSeek Harness 仍处于 developer preview，存在破坏兼容性的可能，因此部署时必须记录实际版本，不应把本文中的命令视作永久版本契约。

- DeepSeek Harness 官方：npm 运行方式为 npx @deepseek-ai/dsh web，默认 Web UI 127.0.0.1:3080。
- DeepSeek Harness 官方：Windows 使用 PowerShell shell 工具栈；自建模型可通过 Custom model API 接入 OpenAI Chat Completions。
- llama.cpp 官方：Windows 支持 winget/conda 等安装，并可运行 OpenAI 兼容 llama-server。
- 附件 MT200 报告：原设备本地模型路径已打通，NPU Genie/FastRPC 尚未打通，因此 Windows 迁移设计不依赖该链路。