MT200 DeepSeek Harness 7B NPU 本地部署验收与扩展分析

成功参数 · 双端硬件 · 架构取舍 · 参数量与量化空间 · 性能、上下文与散热瓶颈

报告日期：**2026-10-28** · 部署目标：**本机浏览器访问 + MT200 NPU 推理** · 模型：**DeepSeek-7B W4A16**

数据口径：本次终端实测、systemd 状态、Genie profile、QNN 配置与既有 MT200 报告；敏感 token、密码、凭据和模型文件不入报告。

1. 执行摘要

最终结论：链路已经跑通。用户从本机 `127.0.0.1:3080` 进入 DeepSeek Harness，SSH 隧道把请求送到 MT200；MT200 上的 dsh 通过 OpenAI 兼容桥调用 Qualcomm Genie，最终由 Hexagon V73 NPU 执行 7B W4A16 模型。两轮连续会话验收成功，服务均开机自启。

7B	12.89	30 s	1024
当前 NPU 模型档位	短提示 decode，tok/s	DSH 连续两轮总墙钟	bundle 固定总上下文

- **成功之处：**NPU 中文出词、OpenAI Chat Completions、SSE 完成事件、DSH Web、新会话历史记忆、服务化和本机入口均已验证。
- **关键修复：**按 DeepSeek Harness 官方 minimal persona 机制设置 `complete: true` 与 `includeRuntimeContext: false`，把 Web 首轮提示从溢出的规模压到 1024-token bundle 可承载范围。
- **没有伪装：**这不是 FP16 权重模型。当前是 W4A16，即权重 INT4、激活 FP16；纯 FP16 7B/8B 权重分别约 14/16 GB，超过 MT200 物理内存。
- **当前边界：**现有 bundle 的 1024 token 是编译期硬上限，当前只能做短对话；工具 schema、长历史、文档分析和完整 Agent 暂不成立。

2. 最终架构与数据流

本机浏览器
127.0.0.1:3080
带动态认证 token

→

SSH 隧道
USB 转网口
10.42.0.1 ↔ 10.42.0.81

→

dsh Web
MT200 loopback:3080
0.2.1-rc.2

→

OpenAI Bridge
loopback:8090
SSE 兼容

→

Genie / QNN
DeepSeek-7B W4A16
Hexagon HTP V73

层	组件与地址	职责	当前状态
访问层	本机 `http://127.0.0.1:3080`	浏览器 UI；首次使用 dsh 动态 token 建立认证 Cookie	可用
传输层	SSH local forwarding，经 `ssh mt200`	只在本机暴露入口，不把 dsh 直接开放到其他网段	可用
Harness	`dsh-web.service`	会话、提示组装、模型路由和 Web UI	active / enabled
兼容层	`npu-openai-bridge.service`	OpenAI 消息转 DeepSeek prompt；Genie 输出转 JSON/SSE	active / enabled
推理层	Genie 1.13 + QNN/AI-RT 2.39	加载 context binary，调度 HTP/NPU	中文出词
硬件层	QCS9075 / Hexagon V73	执行 W4A16 推理	NPU 路径

3. 成功部署参数

3.1 DeepSeek Harness provider 与最小 persona

```
# /home/ubuntu/.dsh/profiles/{web,headless}/cordis.patch.yml（关键项）
provider: meig-npu
model: deepseek-7b-npu
api: openai-completions
baseURL: http://127.0.0.1:8090/v1
contextWindow: 1024
maxTokens: 256
compat:
  supportsDeveloperRole: false
  maxTokensField: max_tokens
persona:
  prefix: You are a concise Chinese assistant. Answer directly and briefly.
  complete: true
  includeRuntimeContext: false
```

`complete` 让 persona 成为唯一系统提示段；`includeRuntimeContext: false` 关闭可选运行时上下文。两项必须同时使用，否则 Web bundle 仍会注入身份、开发环境说明、目录上下文和工具相关文本。

3.2 QNN/Genie bundle

参数	实测/配置值	说明
模型 ID	`deepseek-7b-npu`	OpenAI bridge 暴露名称
bundle 目录	`/data/local/tmp/qnn/deepseek-7b`	设备本地；不提交 Git
context binaries	5 个，合计 4,400,266,688 B；目录 4,405,880,637 B	约 4.10 GiB / 4.40 GB
精度	W4A16	INT4 权重、FP16 激活
上下文	**1024 tokens**	**编译期固定，修改 YAML 不能真正扩容**
词表	102,400	大词表增加 embedding/输出层和固定内存开销
KV / 位置维度	`kv-dim=128`；`pos-id-dim=64`	由 bundle 图定义
后端	`QnnHtp`，burst profile，weight sharing	当前有效组合
并发	单对话锁	避免多个 Genie 进程争抢 DSP 和内存

3.3 服务与安全边界

```
npu-openai-bridge.service  active / enabled  NRestarts=0
dsh-web.service            active / enabled  NRestarts=0
llama-server.service       inactive / disabled
```

- dsh 与 bridge 都绑定 MT200 的 loopback；本机通过 SSH 隧道访问。
- bridge 峰值 cgroup 内存约 5.52 GB；dsh Web 峰值约 308 MB。
- 认证 token 每次 dsh 重启会变化，只从 journal 临时获取，不写入仓库或报告。
- 8B CPU 服务已禁用，防止重启后与 NPU 服务争抢内存并再次过热。

4. 双端硬件与软件参数

4.1 本机电脑

项目	参数	本方案中的作用
机型	HUAWEI NDZ-WXX9	浏览器、SSH 客户端和端口转发
操作系统	Ubuntu 22.04，Linux 6.8.0 系列，x86_64	本机入口和运维终端
CPU	Intel Core i5-1135G7，4 核 8 线程，0.4–4.2 GHz	本次不承担模型推理
GPU	Intel Iris Xe（TigerLake-LP GT2）	本次不承担模型推理
内存	8,115,830,784 B（7.56 GiB）；swap 24,590,147,584 B	不适合本机常驻 7B FP16
存储	512 GB NVMe	代码和报告存储
网络	USB 网卡 `10.42.0.1/24`	直连 MT200 `10.42.0.81`
运行时	Node.js 22.23.1；Python 3.10.12	运维与辅助脚本

4.2 MT200

项目	参数	证据/备注
设备	Qualcomm Addons IQ 9075 EVK，Meig Board V1.00	device tree model
SoC	QCS9075 / IQ-9075 平台	厂商平台资料与现有报告
CPU	8 × Cortex-A78C，1.267–2.362 GHz	`lscpu`
NPU	Hexagon HTP V73，厂商标称 200 TOPS 稀疏算力	V73 skel / QNN；200 TOPS 不是本次实测吞吐
GPU	Qualcomm Adreno 663	`/dev/dri/renderD128`
内存	11,659,272,192 B（10.86 GiB），无 swap	推理与系统共享
存储	120,261,586,944 B；可用约 74.5 GB	`/dev/sda3`
操作系统	Ubuntu 24.04.4 LTS，Linux 6.8.0-1077.81，arm64	本次终端实测
Harness	DeepSeek Harness 0.2.1-rc.2	`/opt/node22/bin/dsh`
MEIGINE	2026-06-11 包；upstream commit `a7266ba`	设备 manifest

> **模型回答中的环境信息不可信。**验收时模型声称时间为“2023-04-14”且系统为“Ubuntu 20.04.4”。实际设备是 Ubuntu 24.04.4，报告日期是 2026-10-28。由于 1024-token 预算迫使我们关闭 runtime context 和工具，模型无法读取真实时钟与系统信息，只能根据训练记忆猜测。此类回答是幻觉，不是设备遥测。

5. 性能与稳定性实测

路径	场景	prefill / 初始化	decode / 总耗时	结论
NPU 7B W4A16	Genie，21-token 短提示	初始化 10.50 s；prefill 18.62 tok/s；TTFT 1.13 s	13 tokens @ **12.89 tok/s**；总计约 13 s	**当前主路径**
NPU 7B W4A16	OpenAI bridge，“你好”	每请求重新初始化	约 7.85–9.37 s 返回短答	**接口可用**
NPU 7B W4A16	DSH 两轮记忆测试	提示字符数约 638 / 724	正确记忆“蓝鲸”；两轮合计 30 s	**连续会话通过**
CPU 8B Q4	25-token 直接请求	38.90 tok/s	8.64 tok/s；总计 1.86 s	**短提示看似可用**
CPU 8B Q4	DSH 约 2.8K 提示	处理 2048 token 已耗 98.18 s，仅 20.86 tok/s	用户长时间无响应	**不适合交互**

> **散热结果：**CPU 8B DSH 请求把监测到的最高热区推到 **114.8°C**，服务停止时一度无法正常响应 SIGTERM，最终强制终止。开启风扇并改用 NPU 后，连续两轮测试完成时约 57.7°C；较长 NPU 请求曾达到约 86.1°C。结论是必须保持主动风冷，并补充 90°C 温度门禁。

6. 两个关键故障及修复

6.1 pi-ai context overflow

阶段	现象	根因	修复
初始接入	`pi-ai detected context overflow`	只删工具不够；Web 全局提示约 2752 字符、runtime context 约 716 字符，另有 working-directory schema。bridge 上报的 input usage 估算为 1764/1765，超过 1024。	采用官方 minimal persona 机制：`complete: true` + `includeRuntimeContext: false`；新建会话。
修复后	两轮短对话成功	提示收敛到数百字符，bridge usage 估算低于窗口	保留 chat-only；工具全部禁用

注意：bridge 当前用字符长度近似填充 OpenAI usage，这不是 DeepSeek tokenizer 的精确计数；但 bundle 的 1024 上限是真实硬约束。

6.2 SSE/finish_reason 兼容

原 bridge 无论客户端是否请求流式都返回普通 JSON，pi-ai 报 `Stream ended without finish_reason`。修复后，`stream=true` 返回 `text/event-stream`，先发送内容 chunk，再发送 `finish_reason: stop`，最后发送 `[DONE]`。当前 Genie 是一次性 CLI，所以这是“完成后一次性 SSE”，不是逐 token 流式。

7. 参数量提升与量化可能性

本节把用户提出的“提高参数和量化”理解为：在 MT200 上提高模型参数量，同时选择能放入内存并可由 QNN/Genie 执行的精度。

方案	仅权重粗算	上下文/固定开销后	可行性
7B FP16	约 14 GB	大于 15 GB	**不可能：权重已超过 10.86 GiB**
8B FP16	约 16 GB	大于 17 GB	**不可能**
7B INT8 / W8A8	约 7 GB	加图缓冲、KV 和系统后接近或超过设备容量	**没有安全余量**
8B INT8 / W8A8	约 8 GB	固定开销后明显超限	**不可用**
当前 7B W4A16	bundle 约 4.40 GB	bridge cgroup 峰值约 5.52 GB	**已运行；但上下文仅 1024**
8B W4A16 + GQA	约 4.5 GB	若固定开销 ≤1.5 GB：4K 约 6.5 GB，8K 约 7.0 GB	**需厂商重新制作 bundle**
3B/4B W4A16 + 8K	约 1.7–2.3 GB	内存余量明显更大	**最稳妥的长上下文 NPU 备选**
W3/W2	更小	依赖算子支持、校准数据和质量评估	**理论可行，当前无可用 bundle**

7.1 8B + 长上下文成立的必要条件

1. **W4A16：**权重必须保持 4 bit 级；FP16 只用于激活/计算。
2. **GQA 且 KV heads ≤ 8：**把 KV cache 控制到约 128 KB/token；4K 约 0.5 GB，8K 约 1.0 GB。
3. **词表 ≤ 32K，或共享/拆分 embedding 与输出层：**当前 102.4K 词表会增加固定开销。
4. **固定开销 ≤ 1.5 GB：**需在图缓冲、激活和 HVX 工作区上优化；不能沿用约 3.3 GB 的旧开销。
5. **bundle 编译 context=4096/8192：**运行时改 JSON 不能替代重新导出。
6. **batch=1：**当前是单用户 Agent，不应为无用并发支付内存。

7.2 模型选择优先级

优先级	模型方向	理由
P0	7B/8B W4A16，8K context，GQA	质量、Agent 提示容量和 NPU 速度最均衡
P1	3B/4B W4A16，8K context	若 8B 内存优化失败，优先保住完整 Agent 上下文
P2	8B Q4 GGUF，CPU 离线批处理	不依赖厂商 bundle，但交互慢且存在严重散热风险
不建议	7B/8B FP16 权重；更大 dense 模型	物理内存不成立

8. 当前瓶颈

瓶颈	直接影响	根本解法
1024-token 编译窗口	只能短对话；完整工具 schema 和长历史无法进入模型	重新导出 4K/8K QNN bundle
Genie 每请求新进程	每轮支付约 7–10.5 s 初始化；没有真正流式首字	常驻 Genie API，或修复可用的 save/restore
bridge 无 tool_calls	当前必须关闭工具，不能形成完整 Agent 闭环	增加函数调用模板、解析器和 OpenAI tool_calls/result 映射
pi-ai 面向大窗口设计	其输出预算逻辑保留较大安全空间；1K 路由需要极简兼容配置	优先换长上下文 bundle，不应虚报 contextWindow
内存无 swap	模型、KV、dsh 和系统抢同一 10.86 GiB；失败时可能直接 OOM	压固定开销；限定单并发；保留系统余量
散热	CPU 8B 达 114.8°C；NPU 长请求也需风冷	主动风冷 + 90°C 硬门禁 + 负载限时
模型不接地	会编造时间、OS 和设备状态	长上下文后恢复最小系统工具；当前由 bridge 注入少量可信元数据
峰值 TOPS 与 LLM 不等价	单序列 decode 受访存、图和调度限制，远低于 200 TOPS 标称	看 tok/s、TTFT、内存和温度，不用 TOPS 单点判断体验

9. 下一步设计

1. **先保设备：**新增独立温度守护；任一关键热区 ≥90°C 时拒绝新请求并停止推理，降至 75°C 后才允许恢复。
2. **向厂商索取真正可验收的 bundle：**7B/8B W4A16、GQA、8K context、batch 1、固定开销 ≤1.5 GB，并交付量化参数和性能 profile。
3. **把 Genie 常驻：**当前 CLI 每轮冷启动。应使用 Genie API 保留 dialog，或先验证可靠的 state restore，目标把短问答从约 17 s 降到 3–6 s。
4. **恢复真实流式：**当前桥接必须等待 Genie 退出才发送 SSE。改用 token callback 后，用户可在约 TTFT 时看到首字。
5. **补最小工具闭环：**优先只开放时间/系统信息与一个受限 shell 工具；但前提是 context ≥4K 且 bridge 支持 tool_calls。
6. **做可重复验收：**固定短对话、两轮记忆、4K/8K 长提示、10 轮稳定性、温度、内存峰值、NPU 利用率和回答接地性。

10. 运维与复现

```
# 连接设备
ssh mt200

# 检查服务（不显示凭据）
systemctl status npu-openai-bridge dsh-web --no-pager
systemctl is-enabled npu-openai-bridge dsh-web

# 在 MT200 上检查模型列表
curl -sS http://127.0.0.1:8090/v1/models

# 本机 SSH 隧道
ssh -N -L 127.0.0.1:3080:127.0.0.1:3080 mt200

# 获取本次 dsh 启动生成的 URL；不要提交输出中的 token
ssh mt200 "journalctl -u dsh-web -n 30 --no-pager -o cat"

# 查看温度（毫摄氏度）
ssh mt200 'cat /sys/class/thermal/thermal_zone*/temp'
```

> **会话规则：**每次 profile 或模型发生变化后必须新建会话。现有会话会保留 preset/model 选择和历史消息；旧会话可能继续携带已经超预算的系统提示。1024-token 版本连续几轮后也可能再次溢出，应主动新建会话。

11. 验收结论

验收项	结果	证据
MT200 连通	**通过**	`ssh mt200`；USB 网段 10.42.0.0/24
NPU 7B 中文出词	**通过**	Genie 返回“你好，我是 DeepSeek Chat……”
OpenAI models/chat	**通过**	`/v1/models` 与 `/v1/chat/completions`
SSE finish_reason	**通过**	内容 chunk → stop chunk → `[DONE]`
DSH 单轮	**通过**	约 17 s 返回“你好！”
DSH 两轮历史	**通过**	记住并正确复述“蓝鲸”；总计 30 s
工具 Agent	**未通过/未启用**	1024 context 与 bridge tool_calls 能力不足
4K/8K 上下文	**未具备**	需要重新编译 QNN bundle
热稳定性	**有条件通过**	必须持续风冷；尚未部署自动温度门禁

12. 数据来源

- 本次设备实测：`hostnamectl`、`lscpu`、`free`、`systemctl show`、Genie profile、bridge journal 与两轮 dsh 验收。
- 仓库既有报告：`MT200/gpu-npu-35b_report.md`、`MT200/reports/mt200-status.html`、`MT200/migration_report.md`。
- 部署输入文档：`/home/jedyying/Documents/MT200/report` 下的部署报告、差距报告与 8B bundle 需求规格。
- DeepSeek Harness 官方仓库：github.com/deepseek-ai/deepseek-harness；Persona 与 provider 配置说明。

口径声明：本文中的“实测”来自本次设备命令或已留存的运行日志；“厂商标称”明确标注；8B 内存预算属于工程推算。模型生成的时间、操作系统描述不作为事实来源。报告未包含 SSH 密码、dsh token、API key、credentials、模型权重或私有会话内容。