MT200 本地 DeepSeek Harness 部署与 200 TOPS 算力利用 · 进展报告

工程进展小结 · 面向「端侧本地 Agent + NPU 算力压榨」目标

报告日期：**2026-10-24** · 目标设备：**MT200 AI BOX（Qualcomm QCS9075）** · 对照设备：**ThinkPad（Core 7 240H / 32 GB / Intel iGPU）**
执行环境：Hermes Agent v0.22.5 · 代码仓库：**C:\AI**（git 10 次提交） · 依据：《DeepSeek Harness MT200→Windows ThinkPad 移植设计文档 v1.0》

一、当前进度（一句话）

迁移闭环 100% 完成（ThinkPad 20/20 轮通过）；**GPU 已用起来**（iGPU Vulkan，冷 prefill 2.55×）；**35B 以上已跑通**（Qwen3.5-35B-A3B，MoE，Agent 3/3）；**MT200 的 200 TOPS NPU 已跑通并封装成 OpenAI 接口**（7B @ 12.09 tok/s）。
唯一未闭环：NPU 模型包上下文仅 1024 token，装不下 dsh 约 2.6K 的 Agent 提示——这一步需要重新导出 QNN bundle，不在本机可解范围。

20/20	12.09	608	0.38
dsh 工具闭环验收（CPU 与 GPU 各 20 轮）	NPU 上 7B 模型 decode (tok/s)	NPU prefill 峰值（tok/s）	CNN 并发实测算力 (TFLOP/s)

二、本周完成的四件事

1. MT200 → ThinkPad 迁移（设计文档 P0）

- 用 **与 MT200 逐字节相同**的模型（sha256 `8dc9e01a…`，1,229,453,568 B），启动参数与 MT200 完全一致（`-c 12288 -t 4 -np 1 --jinja -ngl 0`），因此性能可直接对照。
- dsh 0.2.1-rc.2，独立 `DSH_HOME=C:\AI\dsh-home`，两个 profile（headless / web），工具集裁到 pwsh / fs / fs-search。
- 修复了三个真实故障：MSYS 路径传给原生 exe 导致模型加载失败；`C:\AI\dsh` 缺 WRITE_OWNER 导致 dsh 的 Windows ACL 沙箱置备失败（Win32 5）；web profile 默认禁用 shell 工具。
- **验收 20/20 PASS**：每轮 1 次 tool_call、1 条 completed 结果，答案数字必须能对上 tool_result（接地判定）。单回合 17.2 s，decode 19.4 tok/s。

2. GPU（Intel iGPU / Vulkan）已用起来

场景（1.7B）	CPU `-t 4`	iGPU Vulkan	提升
冷 prefill（2630 token）	19.5 s / 135 tok/s	**7.7 s / 343 tok/s**	2.55×
decode（2630 token 上下文）	19.96 tok/s	**27.31 tok/s**	1.37×

20 轮端到端回合均值	17.2 s（昨夜）	22.4 s（今早）	**同时段 CPU 对照 22.0 s，二者不可区分**

结论：GPU 该开（冷启动、长 prompt、35B 都受益，且从不更慢），但 agent 稳态回合几乎全走前缀缓存（每轮只 prefill 146–209 token），GPU 的冷 prefill 优势被缓存吃掉——不要指望它把回合整体提速。

3. 35B 以上大模型（MoE）已跑通

dense 35B 在 DDR5-5600 双通道（≈90 GB/s）上理论极限只有 4–5 tok/s，因此选 **Qwen3.5-35B-A3B**（35B 总参 / 3B 激活，UD-Q3_K_XL 16.6 GB，sha256 `fef37f41…`）。

配置	prefill tok/s	decode tok/s	备注
纯 CPU `-t 8`	32.0	3.67	不占 GPU 堆
iGPU 30/48 层，16K ctx	36.0	4.49	
iGPU 40/48 层，8K ctx（当前默认）	**50.5**	**5.71**	40 层是硬上限，42 层分配失败
IQ3_XXS 全 48 层驻留（13.1 GB）	25.3	3.44	**更慢：IQ 量化在 Vulkan 上反量化开销大**

Agent 闭环 **3/3 PASS**，回合 44–90 s；算术正确（同一道 C 盘题，1.7B 会十进位错，35B 准确）。

4. MT200 的 NPU：从「不可用」到「已实测 12 tok/s」

> **更正**：我最初的结论是「NPU 不可用」，这是错的。真实原因是只测了 llama.cpp 的 `ggml-hexagon` 通道（它加载自编译的未签名 HTP skel，被安全启动拒绝，错误 `0x80000406`）。MT200 上装有完整 **Qualcomm QNN/AI-RT 2.39** 与签名 skel，走 QNN 这条路 NPU 是活的。

- **官方校验通过**：`qnn-platform-validator --backend dsp --testBackend` → `Unit Test on the backend DSP: Passed`（HTP V73）。
- **7B 模型在 NPU 上出字**：`deepseek-7b` QNN bundle，Genie 1.13，输出通顺中文。
- **QNN profile 实测**：初始化 7.11 s（每次进程）、prompt 处理 25.2 tok/s（28 token 短 prompt）、TTFT 1.11 s、**生成 188 token @ 12.09 tok/s。**
- **已封装为 OpenAI 兼容接口**：`http://10.42.0.81:8090/v1`（模型 `deepseek-7b-npu`），从 ThinkPad 直连调通，一次问答 11.1 s。
- **上下文翻倍**：模型配置写的是 `context_size: 1024`，dialog 只给了 512；改为 1024 后 681 token 的 prompt 正常返回，prefill 达 **607.9 tok/s。**

三、200 TOPS 压榨实验（本轮重点）

3.1 先算清「用掉了多少算力」

单序列自回归推理是**访存受限**，不是算力受限。按每 token ≈ 2×激活参数 FLOP 折算：

阶段	实测速率	折合算力	占 200 TOPS 峰值
LLM decode	12.24 tok/s	0.06–0.17 TOPS	0.03%–0.09%
LLM prefill（681 token）	607.9 tok/s	2.9–8.5 TOPS	1.5%–4.3%

区间下限按 2.4B 激活参数（V2-Lite 类）估算，上限按 7B dense 估算；bundle 的 `n_vocab 102400 / bos 100000` 指向 DeepSeek-V2-Lite 系列。

3.2 逐项压榨：哪些有效、哪些无效

尝试	结果	说明
`vtcm_mb: 8`	**无变化（184.1/12.32）**	VTCM 由图的编译期决定，运行时改不动
`num_hvx_threads: 4`	**无变化（184.1/12.35）**	同上
`sustained_high_performance`	**更差 25%（161.4/9.29）**	突发推理用 `burst` 才对
两进程并发（LLM）	**不提吞吐**	整机 load 冲到 27，sshd 一度失联；DSP 对 LLM 是串行的
`--save` / `--restore`	**restore 失败**	每次请求仍要付 7–8.5 s 初始化
context 512 → 1024	**成功**	唯一有效的配置项，可用上下文翻倍；2048 加载失败
长 prompt（681 token）	**prefill 607.9 tok/s**	固定开销被摊薄，是 prefill 的真实峰值

3.3 换 CNN 负载压吞吐：并发能叠加，但很快撞墙

用 SDK 自带的 yolov8n W8A8（640×640，约 8.7 GFLOP/次）做吞吐扫描，每档 20 次推理/进程：

并发进程	总推理数	墙钟	吞吐	折合算力
1	20	1.67 s	11.98 inf/s	0.10 TFLOP/s
2	40	1.73 s	23.12 inf/s	0.20 TFLOP/s
4	80	1.85 s	**43.26 inf/s**	**0.38 TFLOP/s**
8	160	2.03 s	**失败**	11 条真实错误
16	320	2.17 s	**失败**	88 条真实错误
24	480	2.28 s	**失败**	169 条真实错误

8 个并发起报错，根因是 FastRPC 会话数上限，不是算力不足：

```
DspTransport.openSession qnn_open failed, 0xffffffff, prio 100
IDspTransport: Unknown rpc status 0x000003ff
Failed to load skel, error: 1002
```

结论：这台设备上「能榨出的算力」有明确天花板。
· LLM 单序列：decode 0.06–0.17 TOPS、prefill 2.9–8.5 TOPS；
· CNN 多会话：最多 4 个并发，≈43 inf/s ≈ **0.38 TFLOP/s**（约峰值的 0.2%）；再多进程被 FastRPC 会话上限拒绝；
· 混跑/并发均不叠加：LLM 会话串行，LLM+CNN 互相拖慢（CNN 12→4 inf/s）。
· 200 TOPS 是**稀疏 INT8、大批量、理想数据复用**下的峰值指标，单模型小批量永远到不了。要接近它，需要「大 batch + 高复用」的负载形态（如批量 embedding/分类），而不是跑一个 7B 对话。

3.4 并发与混跑：不能叠加

场景	LLM decode	CNN 吞吐	整机负载	结论
单独 LLM	12.43 tok/s	—	0.7	基线
两个 LLM 会话并发	12.42 tok/s（第二个失败）	—	20.0	不叠加，DSP 串行
LLM + CNN 同时	12.32 tok/s	4.02 inf/s（单独 11.98）	16.1	两边都变差

另外两项也试过：`spill-fill-bufsize` 32/128/256 该图不支持（加载失败）；`mmap-budget 256` 无变化（183.9/12.22）；关闭权重共享反而掉 30%（149.7/8.57）。SNPE 运行时在本机不可用（只有主机端工具，报 "No network connection detected"）。

3.5 硬件事实（用于判断上限）

项	值
SoC	Qualcomm **QCS9075**（soc_id 676，SA8775P 家族；美格 IQ-9075 模组）
CPU	8 × Cortex-A78C（aarch64）
NPU	Hexagon NPU / **HTP v73**（`libQnnHtpV73Skel.so` 证实）
内存	11,119 MB LPDDR（可用 ~7.7 GB），CMA 仅 167 MB
整机定位	汽车/工业级 SA8775P 平台，带 fastrpc-cdsp、CAN-FD 等

四、当前卡点与下一步

卡点	影响	解法
NPU bundle context 只有 1024	dsh 的 Agent 提示约 2.6K，装不下，NPU 目前只能当独立 OpenAI 服务用	用 QNN SDK（x86 主机）按 ≥4K context 重新导出，或向美格索取长上下文 bundle；桥接层已写好，改一行 `CONFIG` 即可接入

1.5B bundle 加载失败	少了一个更快的模型选项	其 KV 融成单个 313 MB dmabuf，超过本机可映射上限（CMA 167 MB）；需重新导出或调大 CMA（需改设备树）
FastRPC 会话上限（4）	CNN 吞吐卡在 43 inf/s	用 batch 而非多进程（当前 bundle 的 batch 维度固定为 1，需重新导出）

建议的下一步（按收益排序）

1. **拿到 ≥4K context 的 QNN bundle**：一步同时解决「NPU 托管 Agent」和「更大上下文」两件事，是本项目最有价值的投入。
2. **把 NPU 用在对的负载上**：批量 embedding / 文档分类 / 图像推理（yolov8n 已验证可用），这类 prefill 密集型任务才吃算力。
3. **ThinkPad 侧维持现有三档**：1.7B（17 s/回合，日常）、35B-A3B（60 s/回合，重活）、iGPU 默认开启。
4. **可选**：SYCL 后端（GitHub 带宽不足未测，理论 prefill 可再高）、llama-server 加 `--api-key`（已完成）。

五、交付物

路径	说明
`C:\AI\README.md`	总览、复现命令、开机自启说明
`C:\AI\migration_report.md`	迁移验收报告（20 轮明细、故障处理、GPU 对照）
`C:\AI\gpu-npu-35b_report.md`	GPU / NPU / 35B 实测报告（含 200 TOPS 压榨记录）
`C:\AI\scripts\`	start-dsh.ps1 / switch-model.ps1 / accept20.py / bench*.py / npu-openai-bridge.py / mt200-*.js
`C:\AI\dsh-home\profiles\`	thinkpad-local / thinkpad-web / thinkpad-35b / thinkpad-web-35b 四个 profile 补丁
`C:\AI\logs\rounds\`	20 轮验收的事件流与 summary.json（机器可读）

运行态：ThinkPad `:8080`（1.7B / iGPU / API key）、`:3080`（dsh Web UI）、`:8081`（35B，按需切换）；MT200 `:8090`（NPU OpenAI 桥）、`:8080/3080`（原服务，未改动）。