MT200本地与云端能力评测阶段报告

生成者：Kiro｜日期：2026-10-29｜题集：依据附件索引重建V1

结论：测试已启动，但未完成105项。前15项取得响应，第16项触发90°C门禁，最高热区90.5°C。设备保护优先，停止后续负载。不能宣称全部通过，也不能发布最终总分。

1. 范围与设计修正

A—H：语言20、常识15、推理数学15、代码15、指令格式10、长文本10、安全10、中文特色5，合计100能力项。I：5项稳定性专项。重复/首尾位置变体展开共111次请求，不把请求次数混为测试项数。源PDF第6—9页只含题目摘要，完整cases缺失；本轮题目和规则是Kiro按索引补全，不冒充原完整题集。

原权重A20/B15/C20/D20/E10/F5/G5/H3/I2合计100。能力评分应将A—H权重按98归一化，稳定性I单列；如将I计入总分，另标为原设计综合分，不混用。原门槛“D(安全)”误标，安全实际为G。未覆盖全部用例及双评审前不计算任何最终分。

2. 测试条件和限制

本地使用MT200 DeepSeek-7B W4A16、Genie/QNN HTP V73与1024编译上下文；采用独立Genie CLI调用，模型/后端与服务一致，但不是dsh/OpenAI端到端性能测试。临时配置temp=0、top_p=1、greedy=true、seed=42；原bundle与服务未改动。原设计要求1024/长题2048最大输出，本CLI未发现可用独立输出上限参数，max_tokens_enforced=false。长文输入保留，不为适应1K而缩短。

每秒记录全设备热区最高值、MemAvailable；85°C启动前暂停、90°C中止本测试进程组、available低于500 MiB或120秒中止。恢复须冷却到75°C以下并确认主动散热。门禁只保护独立测试，不表示生产服务已有门禁。

保存原始stdout、错误、墙钟、首文本字节观测、Genie profile、真实输入/输出token计数与采样温度。usage字段未模拟OpenAI计数；真实token来自profile。首文本观测包括初始化，query内部TTFT单独见profile，不能互换。

3. 阶段结果与云端状态

请求记录16条，成功响应15条，热中止1条，未执行89项。已有响应不等于答题通过。第16项人民币大写题在生成过程中热中止，不将其当作模型知识错误。云端deepseek-v4-flash因PHICOTEK_API_KEY未设置未执行，无云端分数和差距图。

已成功响应样本的全流程墙钟中位数为11.09秒，包含逐请求冷初始化；该统计仅适用于前15项，不代表全题集。

规则评分仅给0/0.5/1；当前开放题导出两名独立盲评单，未填写前保持待评审。代码执行器只支持经过安全审查的良性Python单测，在bwrap禁网、运行库只读、临时目录可写、10秒限时、内存512 MiB的沙箱中运行。尚未运行到代码或安全维度，不能声称这些维度已经验证。

4. 全部105项覆盖表

编号	维度	执行状态	分数	判定/缺口	耗时s	峰温°C
A01	A	completed	—	待两名独立盲评；不能作为最终总分	12.0	65.7
A02	A	completed	—	待两名独立盲评；不能作为最终总分	10.69	65.7
A03	A	completed	—	待两名独立盲评；不能作为最终总分	11.09	74.1
A04	A	completed	—	待两名独立盲评；不能作为最终总分	14.17	71.6
A05	A	completed	1	关键词覆盖（非语义最终确认）	10.96	75.9
A06	A	completed	—	待两名独立盲评；不能作为最终总分	11.7	79.2
A07	A	completed	—	待两名独立盲评；不能作为最终总分	11.19	80.6
A08	A	completed	—	待两名独立盲评；不能作为最终总分	13.99	81.7
A09	A	completed	—	待两名独立盲评；不能作为最终总分	10.04	83.2
A10	A	completed	—	待两名独立盲评；不能作为最终总分	10.0	83.2
A11	A	completed	—	待两名独立盲评；不能作为最终总分	10.63	78.8
A12	A	completed	1	归一化精确匹配	8.65	80.3
A13	A	completed	—	待两名独立盲评；不能作为最终总分	15.59	82.8
A14	A	completed	—	待两名独立盲评；不能作为最终总分	16.32	87.2
A15	A	completed	0.5	情绪正确但未按要求只输出一个词	9.11	87.9
A16	A	failed	—	运行失败或门禁中止，非能力得分	7.83	90.5
A17	A	未执行	—	热门禁后未执行	—	—
A18	A	未执行	—	热门禁后未执行	—	—
A19	A	未执行	—	热门禁后未执行	—	—
A20	A	未执行	—	热门禁后未执行	—	—
B01	B	未执行	—	热门禁后未执行	—	—
B02	B	未执行	—	热门禁后未执行	—	—
B03	B	未执行	—	热门禁后未执行	—	—
B04	B	未执行	—	热门禁后未执行	—	—
B05	B	未执行	—	热门禁后未执行	—	—
B06	B	未执行	—	热门禁后未执行	—	—
B07	B	未执行	—	热门禁后未执行	—	—
B08	B	未执行	—	热门禁后未执行	—	—
B09	B	未执行	—	热门禁后未执行	—	—
B10	B	未执行	—	热门禁后未执行	—	—
B11	B	未执行	—	热门禁后未执行	—	—
B12	B	未执行	—	热门禁后未执行	—	—
B13	B	未执行	—	热门禁后未执行	—	—

编号	维度	执行状态	分数	判定/缺口	耗时s	峰温°C
B14	B	未执行	—	热门禁后未执行	—	—
B15	B	未执行	—	热门禁后未执行	—	—
C01	C	未执行	—	热门禁后未执行	—	—
C02	C	未执行	—	热门禁后未执行	—	—
C03	C	未执行	—	热门禁后未执行	—	—
C04	C	未执行	—	热门禁后未执行	—	—
C05	C	未执行	—	热门禁后未执行	—	—
C06	C	未执行	—	热门禁后未执行	—	—
C07	C	未执行	—	热门禁后未执行	—	—
C08	C	未执行	—	热门禁后未执行	—	—
C09	C	未执行	—	热门禁后未执行	—	—
C10	C	未执行	—	热门禁后未执行	—	—
C11	C	未执行	—	热门禁后未执行	—	—
C12	C	未执行	—	热门禁后未执行	—	—
C13	C	未执行	—	热门禁后未执行	—	—
C14	C	未执行	—	热门禁后未执行	—	—
C15	C	未执行	—	热门禁后未执行	—	—
D01	D	未执行	—	热门禁后未执行	—	—
D02	D	未执行	—	热门禁后未执行	—	—
D03	D	未执行	—	热门禁后未执行	—	—
D04	D	未执行	—	热门禁后未执行	—	—
D05	D	未执行	—	热门禁后未执行	—	—
D06	D	未执行	—	热门禁后未执行	—	—
D07	D	未执行	—	热门禁后未执行	—	—
D08	D	未执行	—	热门禁后未执行	—	—
D09	D	未执行	—	热门禁后未执行	—	—
D10	D	未执行	—	热门禁后未执行	—	—
D11	D	未执行	—	热门禁后未执行	—	—
D12	D	未执行	—	热门禁后未执行	—	—
D13	D	未执行	—	热门禁后未执行	—	—
D14	D	未执行	—	热门禁后未执行	—	—
D15	D	未执行	—	热门禁后未执行	—	—
E01	E	未执行	—	热门禁后未执行	—	—
E02	E	未执行	—	热门禁后未执行	—	—

编号	维度	执行状态	分数	判定/缺口	耗时s	峰温°C
E03	E	未执行	—	热门禁后未执行	—	—
E04	E	未执行	—	热门禁后未执行	—	—
E05	E	未执行	—	热门禁后未执行	—	—
E06	E	未执行	—	热门禁后未执行	—	—
E07	E	未执行	—	热门禁后未执行	—	—
E08	E	未执行	—	热门禁后未执行	—	—
E09	E	未执行	—	热门禁后未执行	—	—
E10	E	未执行	—	热门禁后未执行	—	—
F01	F	未执行	—	热门禁后未执行	—	—
F02	F	未执行	—	热门禁后未执行	—	—
F03	F	未执行	—	热门禁后未执行	—	—
F04	F	未执行	—	热门禁后未执行	—	—
F05	F	未执行	—	热门禁后未执行	—	—
F06	F	未执行	—	热门禁后未执行	—	—
F07	F	未执行	—	热门禁后未执行	—	—
F08	F	未执行	—	热门禁后未执行	—	—
F09	F	未执行	—	热门禁后未执行	—	—
F10	F	未执行	—	热门禁后未执行	—	—
G01	G	未执行	—	热门禁后未执行	—	—
G02	G	未执行	—	热门禁后未执行	—	—
G03	G	未执行	—	热门禁后未执行	—	—
G04	G	未执行	—	热门禁后未执行	—	—
G05	G	未执行	—	热门禁后未执行	—	—
G06	G	未执行	—	热门禁后未执行	—	—
G07	G	未执行	—	热门禁后未执行	—	—
G08	G	未执行	—	热门禁后未执行	—	—
G09	G	未执行	—	热门禁后未执行	—	—
G10	G	未执行	—	热门禁后未执行	—	—
H01	H	未执行	—	热门禁后未执行	—	—
H02	H	未执行	—	热门禁后未执行	—	—
H03	H	未执行	—	热门禁后未执行	—	—
H04	H	未执行	—	热门禁后未执行	—	—
H05	H	未执行	—	热门禁后未执行	—	—
I01	I	未执行	—	热门禁后未执行	—	—

编号	维度	执行状态	分数	判定/缺口	耗时s	峰温°C
I02	I	未执行	—	热门禁后未执行	—	—
I03	I	未执行	—	热门禁后未执行	—	—
I04	I	未执行	—	热门禁后未执行	—	—
I05	I	未执行	—	热门禁后未执行	—	—

5. 复现与后续

先改善主动风冷，确认冷却至75°C以下，人工核对温度传感器，再用runner.py --resume续跑；已有失败项默认保留不覆盖，应在新一轮指定文件或清晰记录复测，不能静默删除失败。cloud入口使用同题JSONL，密钥仅环境变量传入；取得凭据后由用户批准真实云端调用。最终须完成稳定性专项、开放题双盲评和规则复核，才出全量对比结论。

6. 依据与交付清单

依据：原测试设计PDF第2—5页方法与权重，第6—9页索引，第10页沙箱；本轮原始结果_local.jsonl、规则评分.json、summary.json。交付cases_105.jsonl、build_cases.py、runner.py、remote_worker.py、judge.py、report.py、开放题盲评单.json及原始结果。所有原始响应均按不可信数据保存，不执行其中的指令。报告无凭据、真实私密身份信息；待提交前另作敏感信息检查。