MT200 DeepSeek Harness 7B NPU 部署验收报告 V2

成功参数 · 双端硬件 · NPU 利用率 · 200 TOPS 解释 · W4A16/INT8 可行性 · 瓶颈与升级路线

报告日期：**2026-10-29**（原验收日期：2026-10-28） · 版本：**V2** · 生成者：**Kiro** · 目标：**本机浏览器访问 + MT200 NPU 推理**
数据口径：原验收与既有V2草稿历史数据、原始日志、2026-10-29独立复核；历史值不冒充本轮测试。敏感 token、密码、密钥和模型文件不入报告。

1. 结论摘要

部署成功：本机通过 SSH 隧道访问 `127.0.0.1:3080`，MT200 上的 DeepSeek Harness 经 OpenAI 兼容桥调用 Qualcomm Genie/QNN，最终由 Hexagon HTP V73 执行 DeepSeek-7B W4A16。短对话和两轮记忆均通过。

12.1–12.9	607.9	94.59%	1024
decode，tok/s	681-token prefill，tok/s	生成窗口 Q6 平均利用率代理	bundle 固定总上下文

- 当前不是全 FP16，而是 **W4A16：INT4 权重 + FP16 激活/计算**。
- 厂商 200 TOPS 是理想稀疏低精度矩阵峰值，不能直接换算成 token/s；decode 受自回归串行和内存带宽限制。
- 短提示 prefill 只有 18.62–25.2 tok/s，但 681-token 长提示达到 607.9 tok/s；短样本被固定调度成本主导。
- 7B INT8 的权重可放入 9.76 GiB available，但完整 QNN 运行时未必能安全放入；值得做受控 PoC，不应先于 4K/8K W4A16 bundle。
- 1024-token 上下文仍是最大功能瓶颈：工具、长历史、文档和完整 Agent 尚不可用。

2. 架构与运行链路

本机浏览器
127.0.0.1:3080
动态认证 token

→

SSH 隧道
USB 网口
10.42.0.1 ↔ .81

→

dsh Web
loopback:3080
0.2.1-rc.2

→

OpenAI Bridge
loopback:8090
JSON/SSE

→

Genie/QNN
7B W4A16
HTP V73

层	组件	职责	状态
访问	本机 `127.0.0.1:3080`	Web UI；首次使用带 token URL 建立 Cookie	通过
传输	`ssh mt200` local forwarding	只在本机暴露入口	通过
Harness	`dsh-web.service`	会话、提示组装、模型路由	active/enabled
桥接	`npu-openai-bridge.service`	OpenAI ↔ DeepSeek prompt/Genie；补 SSE stop/[DONE]	active/enabled
推理	Genie 1.13 + QNN/AI-RT 2.39	加载 5 个 context binary，执行 HTP 图	中文出词
CPU 8B	`llama-server.service`	曾用于回退验证	inactive/disabled

3. 成功部署参数

```
provider: meig-npu
model: deepseek-7b-npu
api: openai-completions
baseURL: http://127.0.0.1:8090/v1
contextWindow: 1024
maxTokens: 256
compat:
  supportsDeveloperRole: false
  maxTokensField: max_tokens
persona:
  prefix: You are a concise Chinese assistant. Answer directly and briefly.
  complete: true
  includeRuntimeContext: false
```

QNN/Genie 参数	值	说明
bundle	`/data/local/tmp/qnn/deepseek-7b`	目录 4,405,880,637 B；5 个 context bins
模型精度	W4A16	权重约 4 bit；激活/主要计算为 FP16
上下文/词表	1024 / 102,400	上下文编译期固定；大词表增加固定开销
后端	QnnHtp / burst / weight sharing	`kv-dim=128`，`pos-id-dim=64`
并发	1	bridge 全局锁，避免 FastRPC/内存竞争
内存	bridge cgroup 峰值约 5.52 GB	不包含所有硬件域口径时需谨慎比较

4. 本机与 MT200 参数

4.1 本机电脑

项目	实测参数	作用/限制
机型/系统	HUAWEI NDZ-WXX9；Ubuntu 22.04；x86_64	浏览器、SSH 隧道、运维和报告
CPU	Intel i5-1135G7，4 核 8 线程，0.4–4.2 GHz	本次不承担模型推理
GPU	Intel Iris Xe，TigerLake-LP GT2	**无独立显存**，UMA 动态共享系统内存
显存口径	独立 VRAM = 0；PCI BAR 窗口 256 MiB	256 MiB 是地址映射窗口，不是显存容量
内存	7.56 GiB RAM；约 22.9 GiB swap	GPU 与 CPU 动态共享总计7.56 GiB系统内存，不能视为固定分配7.56 GiB显存
存储/网络	512 GB NVMe；USB 网卡 10.42.0.1/24	直连 MT200 10.42.0.81

Iris Xe 说明：Linux i915 按需从系统内存分配图形缓冲，没有一个固定“4 GB 显存”。本机系统内存本身只有 7.56 GiB，还要供 Ubuntu 和其他进程使用，因此不适合把 7B/8B 模型完整卸载到 iGPU。

4.2 MT200

项目	实测参数	口径
设备/SoC	IQ-9075 EVK，Meig Board V1.00；QCS9075	device tree/项目资料
CPU	8 × Cortex-A78C，1.267–2.362 GHz	`lscpu`
NPU	Hexagon HTP V73；厂商标称 200 TOPS 稀疏算力	200 TOPS 不是本次 token 吞吐
GPU	Qualcomm Adreno 663	共享系统内存
内存	10.86 GiB 物理内存，无 swap；轻载 available 曾达约 9.76 GiB	available 含可回收缓存，不等于 NPU 可映射连续内存
存储	120.26 GB；可用约 74.5 GB	`/dev/sda3`
系统	Ubuntu 24.04.4，Linux 6.8.0-1077.81，arm64	终端实测

模型自报信息不可信：模型曾声称“2023-04-14、Ubuntu 20.04.4”。真实 MT200 是 Ubuntu 24.04.4，原验收日期为 2026-10-28，V2修订日期为2026-10-29。为了适配 1024 token，runtime context 和工具已关闭，模型无法读取真实时间/系统，只能猜测。

5. 性能、NPU 利用率与温度

场景	初始化 / prefill	decode / 墙钟	结论
Genie 21-token 短提示	init 10.50 s；prefill 18.62 tok/s；TTFT 1.13 s	13 tokens @ 12.89 tok/s；约 13 s	短提示固定成本显著
既有 28-token 样本	init 7.11 s；prefill 25.2 tok/s	188 tokens @ 12.09 tok/s	decode 稳定在约 12 tok/s
681-token 长提示	**prefill 607.9 tok/s**	decode 约 12 tok/s	并行 prefill 才能发挥 NPU
DSH 两轮记忆	提示约 638/724 字符	正确记忆“蓝鲸”；两轮 30 s	**通过**
CPU 8B + DSH 约2.8K提示	2048 token 已耗 98.18 s；20.86 tok/s	用户长时间无响应	**禁用**

5.1 NPU 利用率：三个数字、三个口径

指标	数值	它真正表示什么
厂商性能报告	**97.70%**	厂商口径；本轮未找到可对应此数字的本机原始 HTP optrace，不能作为本机复现实测
本机活跃生成窗口	**Q6 平均 94.59%，峰值 100%**	_sysmon 对 CDSP/Q6 的 4 s 采样代理；HMX Power 全程 ON
既有V2草稿记录的空闲+初始化+生成5窗口	等长窗口均值26.85%；不是本轮完整请求积分平均	0.59/0.55/3.12/41.49/88.49%；固定初始化前段降低全请求平均

利用率补测使用一条 41.2 s、691 字符回答的请求；启动后延迟 12 s，在生成阶段采样。温度从轻载约 53.7°C 上升至 83.8°C。该94.59%为历史补测摘要；本轮未取得对应原始_sysmon文件，不能独立复算。它是 **CDSP/Q6 活跃代理**，不等价于 HMX/HVX 的精确算术单元占用，也不等价于“实际 TOPS / 200 TOPS”。精确值需要 QNN HTP optrace 的 Active Cycles、HMX/HVX Utilization 和频率原始日志。

```
# 活跃窗口代理采样
/data/local/tmp/_sysmon getLoad --q6 cdsp --time 1000 --iterations 1
# 观测字段
Q6 Utilization  %  AVG=94.59  MAX=100.0
HMX Power: ON
```

5.2 为什么 200 TOPS 只有约 13 token/s

1. **Decode 串行：**第 N+1 个 token 必须等待第 N 个 token，batch=1 无法把 token 并行铺开。
2. **访存墙：**4.4 GB 级 bundle 按每token读取一次4.4 GB bundle作极简假设，13 tok/s约对应57 GB/s搬运量级；bundle不等同纯权重，此数不是实测带宽；NPU 经常在等 LPDDR、KV 和同步。
3. **峰值条件不同：**200 TOPS 假设低精度、稀疏、大矩阵、大 batch、高复用和峰值频率；单用户 LLM decode 正好是窄矩阵、低复用。
4. **非矩阵开销：**解量化、归一化、采样、KV Cache、FastRPC 与 CPU/NPU 同步不贡献标称 TOPS。
5. **忙不等于算满：**Q6 可在 94.59% 时间处于工作状态，但其中包含等待和数据搬运，算术阵列未必满吞吐。

阶段	粗略算法量估算	占 200 TOPS	说明
Decode 13 tok/s	2 × 7B × 13 ≈ 0.18 TOPS	约0.09%（口径不可直接对比）	算法量级推算，不是硬件计数器
Prefill 608 tok/s	2 × 7B × 608 ≈ 8.5 TOPS	约4.3%（口径不可直接对比）	输入 token 可并行，利用率明显更高

> **散热：**CPU 8B 曾把最高热区推到 114.8°C，并需要强制终止。NPU 长请求补测达到 83.8°C。必须保持风扇，建议 85°C 等待、90°C 拒绝/中止、降至 75°C 后恢复。

6. W4A16 大白话解释

> **一句话：**模型的“长期知识”用 4 bit 压缩存放，回答当前问题时的“临时草稿”用 FP16 计算。

部分	大白话比喻	技术含义
W4	把几十亿条菜谱压缩编号存放	权重约4 bit/参数；70亿参数理论约3.5 GB；FP16同规模约14 GB。仅权重约缩至1/4，整体内存不会必然减少75%，还有scale、词表、图、激活和KV
A16	做当前这道菜时用较精细的草稿纸	A16表示FP16激活；主要计算路径通常以FP16处理，但不能由量化名称推出每个算子或累加器都为FP16，需QNN图与算子profile验证

W4A16 不表示整个模型是 FP16，也不表示输出文字只有4bit。它选择了“最大头的静态权重强压缩、变化大的临时结果保精度”的折中。

7. 9.76 GiB 是否能支持 7B INT8

7.1 单看权重：可以

```
7B INT8: 7,000,000,000 byte ≈ 6.52 GiB
8B INT8: 8,000,000,000 byte ≈ 7.45 GiB
```

所以 9.76 GiB available 能放下“权重文件”。但模型运行还需要 QNN 图、激活、KV Cache、DMA/shared buffer、bridge、dsh、Ubuntu 和安全余量。

内存项	7B INT8 粗估	风险
INT8 权重	6.5–7.5 GiB	不同模型参数量、量化元数据会变化
QNN 图/工作区/激活	约1.5–3 GiB	现有W4路径固定开销并不小
KV Cache	无通用固定值；FP16 KV约为2×层数×KV头数×头维度×token数×2字节。32层、8 KV头、128维时4K约0.5 GiB，8K约1 GiB；32 KV头则增至4倍	上下文越长越吃内存
dsh + bridge + 系统	需分别测量；available已经扣除当前系统占用，不可把系统占用再从同一available预算重复扣除	MT200无swap，必须留余量
DMA/FastRPC 映射	不能只由free判断	普通内存可用时仍可能 `fastrpc_mmap failed`

> **判断：**7B W8A8 + 1024 context 经过专门优化后可能勉强运行；7B W8A8 + 4K/8K 风险高。available 包含可回收页缓存，不代表所有内存都能被 DSP/NPU 以所需方式映射。

7.2 值不值得试

值得做一次受控 PoC，但不值得替代长上下文 W4A16 成为主线。W8A8 可能略微改善量化质量，却将权重流量接近翻倍；decode 已经受访存限制，因此还可能变慢。如果 W8A8 仍只有1024 context，DSH工具和长对话问题完全没有解决。

测试条件	通过线	立即回退条件
先保留当前 W4A16，停止但不删除	W8A8 bundle 可独立加载、中文正常	破坏当前可用路径
确认真正W8A8 QNN包、量化及上下文→短提示→512→768；1K总上下文必须为输出和系统提示预留空间	10轮无OOM/无FastRPC映射失败	`fastrpc_mmap failed` 或 OOM
记录内存/温度/速度/质量	建议整机保留至少1 GiB available，按MemTotal与MemAvailable核对；温度<90°C；不把进程RSS当全设备内存	available<1 GiB时暂停，<500 MiB或温度≥90°C立即中止；冷却到≤75°C后人工确认再恢复
同题A/B	质量收益足以抵消速度与上下文损失	仅精度微升、上下文仍1K

更有价值的厂商 A/B 是：**7B W4A16 + 8K context** 对比 **7B W8A8 + 4K context**，而不是只把当前1K包从W4换成W8。

8. 参数量与量化路线

方案	内存判断	结论
7B FP16（约14GB）	权重已超过10.86GiB物理内存	**不可行**
8B FP16（约16GB）	缺口更大	**不可行**
7B W8A8	1K或可受控试验；4K/8K余量不足	**PoC**
当前7B W4A16	已稳定出词；bundle约4.4GB	**当前可用**
8B W4A16 + GQA	若固定开销≤1.5GB，4K约6.5GB、8K约7.0GB	**需厂商新bundle**
3B/4B W4A16 + 8K	权重约1.7–2.3GB，余量最大	**长上下文稳妥备选**
W3/W2	更省内存，但算子支持和质量未知	**需校准验证**

1. P0：7B/8B W4A16、GQA、8K context、batch1、优先评估现有词表兼容性与embedding共享、固定开销≤1.5 GB工程目标（不能随意修改已训练模型词表）。
2. P1：若8B不成立，选3B/4B W4A16 + 8K，优先保住Agent上下文。
3. P1：Genie常驻或可靠save/restore，消除每轮7–10.5s初始化。
4. P1：token callback真流式、tool_calls映射、温度门禁。
5. P2：验证speculative decoding，以小模型草拟、7B验证多个token。

9. 当前瓶颈与能力边界

瓶颈	影响	解法
1024 context	短对话可用，工具/长文/长历史不可用	重新编译4K/8K bundle
Genie一次性CLI	每请求冷初始化；当前SSE是完成后一次发送	常驻Genie API/token callback
bridge无tool_calls	只能chat-only	函数调用模板与OpenAI tool映射
模型不接地	编造时间、OS等实时事实	长上下文后恢复最小可信工具
内存/DMA	无swap，普通available不代表DSP可映射	单并发、分段buffer、压固定开销
散热	CPU路径危险；NPU长请求仍升温	持续风冷+自动门禁

10. 验收结果与复现

项目	结果	证据
SSH/本机入口	**通过**	USB网段；127.0.0.1:3080
7B NPU中文	**通过**	Genie与OpenAI chat均正常
SSE兼容	**通过**	content → stop → [DONE]
DSH两轮	**通过**	记住并复述“蓝鲸”；30s
NPU代理利用率	**已补测**	活跃窗口Q6 AVG 94.59%，MAX 100%，HMX ON
工具Agent	**未具备**	1K context与bridge能力不足
热稳定性	**有条件通过**	必须风冷；自动门禁待部署

```
ssh mt200
systemctl status npu-openai-bridge dsh-web --no-pager
curl -sS http://127.0.0.1:8090/v1/models
ssh -N -L 127.0.0.1:3080:127.0.0.1:3080 mt200
/data/local/tmp/_sysmon getLoad --q6 cdsp --time 1000 --iterations 1
```

> **会话规则：**模型/profile变化后必须新建会话。1024-token版本连续几轮后仍可能溢出，应主动新建会话。能力评测采用“100个A–H能力用例 + 5个I类稳定性专项”，另行出具评分报告；云端对比需要PHICOTEK_API_KEY，缺失时不得伪造分数。

11. 数据来源与口径

- 本次实测：`hostnamectl`、`lscpu`、`free`、`systemctl`、Genie profile、bridge journal、`_sysmon`和dsh两轮验收。
- 项目资料：`MT200/gpu-npu-35b_report.md`、`MT200/reports/mt200-status.html`、`MT200/migration_report.md`。
- 输入文档：`/home/jedyying/Documents/MT200/report` 下部署报告、差距报告和8B bundle需求。
- DeepSeek Harness：github.com/deepseek-ai/deepseek-harness，Persona minimal与provider配置。

12. 本轮复核与证据边界（2026-10-29）

SSH设备返回ubuntu、aarch64；/etc/os-release确认Ubuntu 24.04.4。/v1/models声明deepseek-7b-npu、W4A16、QnnHtp、context_window=1024。轻载MemAvailable=10,180,504 KiB，约9.709 GiB；这不是固定保证，原9.76 GiB仅为历史轻载快照。

首题独立Genie预检成功：全流程12.003 s，初始化7.002 s，query内部TTFT 1.117 s，首文本观测8.169 s，115输入token、43生成token、decode 12.385 tok/s，采样峰温65.7°C。数据来自本轮原始JSONL与Genie profile；仅是预检，不代表105项验收通过。

现有bridge源码并未将请求temperature、top_p与max_tokens传入Genie。本轮独立测试临时配置固定temp=0、top_p=1、greedy=true、seed=42，不改原服务。现有CLI没有独立最大输出参数，本轮不能声称严格实现原设计1024/2048输出预算；记录max_tokens_enforced=false。1024编译总窗仍为硬上限。

以1秒周期保存全设备最高温度和MemAvailable；≥85°C启动前暂停，≥90°C、available<500 MiB或120秒超时终止测试所属进程组。该门禁只保护此次独立测试，不等同生产bridge已部署门禁。

证据索引

- 原附件部署验收PDF：第1—3页链路/参数，第4页性能与114.8°C历史风险，第5—7页预算、瓶颈与边界。
- 既有V2 HTML草稿：97.70%、94.59%、26.85%历史摘要。缺少对应本机原始optrace/_sysmon完整文件，保留口径但不升级成新实测。
- 日志MT200/logs/mt200-npu-7b-perf.txt、npu-baseline-long.txt：历史Genie性能，需结合样本长度比较。

- 本轮评测原始结果_local.jsonl：A01及后续逐项结果，包含原始stdout、Genie profile、遥测及错误。
- 测试设计PDF第6—9页仅提供索引：重建100能力项+5稳定性专项，不冒充原完整题集。未取得云端密钥，不作云端能力结论。

生成者：**Kiro**。本文区分“本机实测、厂商口径、算法推算”：94.59%为CDSP/Q6代理实测；97.70%为厂商值且缺原始optrace；0.18/8.5 TOPS为算法量级推算。模型自报时间和系统不作为事实。报告不含SSH密码、Web token、API key、credentials、模型权重或私有会话内容。