工作日报 · 2026-10-26（周一）

100B+ 大模型可行性任务 · NPU 算力压榨收尾 · 交付物同步

生成时间：**2026-10-27 07:21** · 作者：**thinkpad Hermes** · 工作目录：**C:\AI** · 当日提交：**6 次**（50e3c2e → e315623）
远端：**github.com/JedyYing/RG660MK-EU-AI-CPE** · 涉及设备：ThinkPad（Core 7 240H / 31.5 GB）、MT200（QCS9075）

一、昨日概览

6	3	2	0.72
代码提交	新增报告（MD）	GitHub 推送	106B decode（tok/s）

昨天是这条线的**攻坚日**：上午结束 NPU 压榨的最后一轮排查，下午接下"100B+ 可运行性"任务书并完成阶段一、二，晚间把一个 **106B 参数**的模型真正跑起来（0.72 tok/s），并做了一次影响判断的定论——**在这台机器上，GPU 卸载对超大模型是有害的。**

二、昨天做了什么

1. 交付物收口与同步

- 生成 A4 状态报告 PDF（5 页），修掉一个真实缺陷：Chrome 对微软雅黑子集的 ToUnicode 映射错位，导致 `19.5` 抽成 `a9.5`、`C:\AI` 抽成 `fTdn`；改为 **Segoe UI 优先**后修复，并用 PDFium 逐页渲染验证。
- 发现并移除安全隐患：三个 MT200 脚本里硬编码了设备密码，改为必须通过 `MT_PASS` 环境变量提供。
- 把全部工程产物推到 GitHub 仓库的 `MT200/` 目录：先 227 文件 / 5.7 MB，晚间更新为 **247 文件 / 5.8 MB**；两次都做了远端复克隆校验。

2. NPU 算力压榨收尾（结论：已触顶）

尝试	结果	判定
`spill-fill-bufsize` 32/128/256	该图不支持，加载失败	**无效**
`mmap-budget 256`	183.9 / 12.22（基线 184.4 / 12.25）	无变化
关闭权重共享	149.7 / 8.57，掉 30%	**更差**
两个 LLM 会话并发	第二个失败，decode 仍 12.42，负载冲到 20	**不叠加**
LLM + CNN 混跑	LLM 12.32 不变，CNN 从 12 掉到 4.02 inf/s	**双方变差**
SNPE 运行时	仅主机端工具，报 `No network connection detected`	**不可用**

结论：这台设备的实际天花板是 **LLM 12.4 tok/s**（0.06–0.17 TOPS）与 **CNN 43.26 inf/s = 0.38 TFLOP/s**（4 路并发，峰值的 0.19%）。200 TOPS 是稀疏 INT8 + 大批量的理论值，单序列小批量永远达不到。

3. 100B+ 任务：阶段一（硬件摸底）

项	ThinkPad	MT200
内存（实测）	31.5 GB，空闲 13.5 GB，提交上限 37.4 GB	11.1 GB，可用 **7.6 GB**，**无 swap**
加速器	iGPU / Vulkan，15.4 GiB free	HTP V73，QNN+Genie 可用
模型资产	最大 16.6 GB（35B）	最大 4.5 GB（8B GGUF）/ 4.2 GB bundle
转换工具	不需要	**完全没有（只有 runner）**
磁盘冷读	**1.1–1.9 GB/s**（绕过缓存实测）	—
CMA	—	**167,936 kB 总 / 空闲 0**

4. 100B+ 任务：阶段二（四路线分析）

- **路线 A（ThinkPad 单机）**：可执行，但 100B 类模型现实最小 GGUF 是 27.3 GiB（Scout TQ1_0），必需 mmap 流式。
- **路线 B（MT200 NPU）**：**物理不可能**——7.6 GB 可用 vs 27.3 GiB 起步，差 3.6 倍；且无转换工具、ctx 只有 1024。
- **路线 C（跨设备同模型分层）**：**受阻**——MT200 的 vendor llama.cpp **不含 RPC 后端**（二进制内 rpc 字符串计数为 0），且无 gcc/cmake；即使补齐，NPU 也用不上（HTP 只吃 QNN bundle）。
- **路线 D（两台各跑一个模型）**：已实现（NPU 7B + iGPU 35B），但不是同一模型，不满足任务定义。

三、重大进展：106B 模型在 31.5 GB 笔记本上真跑起来了

项	实测值
模型	GLM-4.5-Air-UD-IQ1_S，**35.86 GiB**，106B 总参 / 12B 激活，MIT 许可
完整性	38,503,140,416 字节；SHA256 `4491e442…0412ab` 与源站一致
运行配置	llama.cpp b11836 **CPU-only**，`-c 2048 -ctk q8_0 -ctv q8_0 -ngl 0 -nkvo`
decode	**0.72 tok/s**（0.54–0.87，5 题中位）
prefill	**0.9 tok/s**（0.57–1.53）
内存占用	31,625 MB / 31.5 GB（余量约 1 GB）

换算：生成 200 token ≈ 4.6 分钟；读入 2048 token 上下文 ≈ 38 分钟。同机 35B-A3B 为 5.71 tok/s，快 8 倍。

最重要的一个反直觉结论：Intel iGPU 的"显存"就是系统内存本身。36 GiB 模型占满 RAM 后，显卡连 400 MB 都申请不到——4 种 GPU 卸载配置全部 OOM，完全关掉 GPU 反而跑通。这说明"有 GPU 就该用"在"模型大于内存"的场景下是错的。

四、遇到的问题与瓶颈

问题	表现	现状
MT200 内存墙	可用 7.6 GB、无 swap、CMA 空闲 0	**无法解决（硬件）**
MT200 无模型转换工具	只有 `qnn-net-run` 等 runner，无 converter / context-binary-generator	**需厂商提供 bundle**
现有 NPU bundle 上下文	1024 token，装不下 dsh 的 2.6K Agent 提示	**等 ≥4K bundle**
100B 的内存需求	35.9 GiB 权重 vs 31.5 GB 物理内存	**靠 mmap 流式，速度受限**
iGPU 与 RAM 同源	GPU 卸载后 Vulkan 侧 OOM，反而更慢/失败	**已定位并绕开**
下载链路不稳	Wi-Fi 实测 ~22 Mbps；hf-mirror 429 限速；分片被旧进程并发写坏（长度翻倍）	**已改用分片字节校验 + 单进程互斥**
IQ1_S 质量损失	5 题中 2 题不合格（答非所问 / 不给数字）	**量化极限，非配置问题**

五、今日（10-27）计划与可改进项

优先级 P0：把"能用"和"能演示"分开

- **35B-A3B 作为日常主力**（5.71 tok/s），106B 定位为"能力上限演示"，不接入 dsh 工作流。理由：0.72 tok/s 连一次 200 token 回答都要 4.6 分钟，prefill 更慢，无法承载 Agent 循环。
- 决定 106B 文件的去留：保留在 `D:\models`（占 36 GB，D 盘余 517 GB）或删除。建议保留但加一个开关脚本，避免误加载拖垮机器。

优先级 P1：把 100B 的结论变成可复用资产

- 把这次的四份文档（摸底 / 路线分析 / 实测 / 日报模板）整理成一份 **《端侧大模型可行性判定手册》**，包含"内存预算表 + 量化换算公式 + 失败模式清单"，下次换设备直接套用。
- 补一个 `mem_budget.py`：输入参数量、量化位宽、上下文长度、设备内存，直接输出"能否驻留 / 预期 tok/s / 推荐配置"，把昨天的算术自动化。

优先级 P2：MT200 侧不再投入算力压榨

- NPU 侧已证明触顶（0.38 TFLOP/s），后续只做一件事：**向厂商索取 ≥4K 上下文的 QNN bundle**，拿到后桥接层改一行配置即可托管 Agent。
- 不再尝试并发/混跑/参数扫描——昨天的数据已经把这些路径全部否掉，重复实验没有信息增益。

优先级 P3：工程卫生

- 清理 `C:\AI\logs` 里 30+ 个早期失败的 QNN 日志（保留结论，丢弃中间产物）。
- GitHub token 已在对话中暴露，**建议尽快吊销重签**；之后推送改用 SSH key 或凭据管理器，不再手写 token。

> **一句话总结**：昨天把"能不能跑 100B"这个问题从猜测变成了实测——**能跑（0.72 tok/s），但不可用**；同时确认 MT200 的 NPU 在 100B 场景下没有任何可能。今天开始把这套判定方法固化下来，并把日常栈稳定在 35B。

数据来源：`C:\AI` git 提交 50e3c2e→e315623；`logs/bench-glm45air-v5.json`；`reports/100B_*.md`；`logs/npu-knobs.txt`、`logs/npu-mixed.txt`。