

RG660MK-EU AI CPE Demo

SG560D AI Assistant 基于 USB 算力棒的迁移设计

V2.1 - Hailo-10H / ASUS UGen300 优先方案

编制日期	2026-08-20
目标平台	Quectel RG660MK-EU
规格基线	Quectel_RG660MK-EU_5G_Module_Specification_V1.0.1_Preliminary_20260819.pdf
迁移来源	SG560D AI Assistant 收尾归档
原设计基线	RG660MK AI CPE Demo: PicoClaw 部署与 SG560D AI Assistant 迁移设计 V1.0
执行目标目录	/home/jedyying/Downloads/AI_CPE_Demo
主要执行者	Claude Code / Ubuntu Host

核心变化：本版不再把 Jetson 作为默认 AI 计算平台，而是把“RG660MK-EU + USB AI 算力棒”作为首选一体化路线；Jetson/外部 AI Box 仅作为 USB Host、驱动、模型兼容或资源稳定性 Gate 失败时的回退方案。

目录

- 0. 审核结论与资料边界
- 1. 设计目标与非目标
- 2. RG660MK-EU 规格基线及对原文修正
- 3. USB 算力棒方案总体架构
- 4. 算力棒选型与边界
- 5. SG560D 功能迁移矩阵
- 6. USB / Camera / Audio / BLE 外设设计
- 7. 软件架构与进程边界
- 8. 模型迁移与 QNN/HTP 替代路线
- 9. 分阶段 Gate 实施计划
- 10. 测试与验收设计
- 11. 风险与回退设计
- 12. 采购配件清单
- 13. 给 Claude Code 的执行总指令
- 14. 最终结论
- 15. 参考资料

0. 审核结论与资料边界

本版设计基于两类资料：

- 附件规格：Quectel RG660MK-EU 5G Module Specification V1.0.1 Preliminary（2026-08-19）。
- 上一版《RG660MK AI CPE Demo：PicoClaw 部署与 SG560D AI Assistant 迁移设计》及其中记录的 SG560D 已验证/未验证能力。
- 补充公开资料：ASUS UGen300 与 Hailo-10H 官方页面，用于 USB 算力棒候选规格与销售区域确认；这些信息不是 Quectel 规格的一部分。

资料边界：Quectel 规格能够确认模组接口和无线/CPU 基线，但不能证明当前 CPE 载板已经把全部 LGA 接口引出，也不能证明当前固件允许加载 HailoRT/第三方内核驱动。所有“可直接运行”的结论必须由实机 Gate 验证。

0.1 对上一版设计的关键修正

项目	上一版	V2.1 修订
接口认知	原文按当前样机“一个 USB + DB9 + RJ45”做设计。	修正为“模组能力”和“当前载板引出能力”两层。RG660MK-EU 规格列出 USB 3.2 Gen2×1、USB 2.0×1、UART×3、USXGMII×2、PCIe 4.0×1、PCIe 3.0×2、PCM×2 等；当前载板仍须盘点。
AI 计算	默认 RJ45 外置 Jetson。	首选 USB 算力棒；Jetson 降级为 fallback。
NPU 假设	不把网络加速单元当 AI NPU，此判断正确。	继续保留；不假设片内 AI NPU/SDK 可用。
音频	以 USB Audio 为主。	继续保留。规格有 PCM×2/可选数字音频，但 Demo 不直接做 PCM Codec 硬件。
USB 带宽	先确认 USB 2.0/3.x。	升级为强制 Gate：算力棒方案要求当前暴露口为 Host；推荐 SuperSpeed，优先 5/10Gbps。
算力棒	旧文仅把 Coral 作为可选。	改为 Hailo-10H / ASUS UGen300 类作为首选候选，Coral 降为轻量 TFLite 备选。

1. 设计目标与非目标

1.1 设计目标

- 保持 RG660MK-EU 的首要角色是 5G CPE：蜂窝注册、WAN、RJ45 LAN、DHCP、DNS、NAT、Firewall 不能被 AI 功能破坏。
- 在 RG660MK-EU 上稳定运行 PicoClaw，作为会话、工具调用和 MQTT/HTTP 编排中枢。
- 利用当前载板暴露的 USB Host 接口外接 AI 算力棒，使 YOLO、人脸、MediaPipe、部分 ASR/VLM 等推理尽量在本机完成。

- 从 SG560D 迁移“能力、协议、模型与测试基线”，而不是强行迁移 Qualcomm QNN/HTP 二进制运行环境。
- 保留 Camera→视觉→MQTT→Home Assistant/灯→PicoClaw 回复的历史闭环，并增加 TTS/连续对话能力。
- 形成可复现、可回滚、可量化验收的交付包。

1.2 非目标

- 不在第一阶段重做 RG660MK-EU 自研载板。
- 不默认 Wi-Fi 8、蓝牙、片内 AI NPU、Android APK Runtime 已可用。
- 不把 40 TOPS/20 TOPS 等理论算力直接等同于 SG560D 上某模型的实际 FPS。
- 不允许第三方 AI Runtime 修改 CPE 核心网络配置或阻塞系统启动。

2. RG660MK-EU 规格基线及对原文修正

2.1 Quectel 规格明确支持的能力

能力	规格结论	来源
CPU	四核 2.34 GHz；规格描述集成网络与 VPN 加速器。	规格 p.1
5G	Sub-6；NSA/SA；5G 6CA；3TX/8RX；n41/n77/n78/n79 等。	规格 p.1-2
USB	USB 3.2 Gen2 ×1；USB 2.0 ×1。	规格 p.2
高速扩展	USXGMII ×2；PCIe 4.0 ×1；PCIe 3.0 ×2。	规格 p.2
低速/多媒体	UART ×3；PCM ×2；SPI ×3；I2C ×4；ADC ×4；SDIO ×1。	规格 p.2
音频	可选 Digital Audio、VoLTE/VoNR；PCM ×2。	规格 p.2-3
Wi-Fi	Wi-Fi 8*，且 * 表示 under development/planning/in progress。	规格 p.1, p.3
电源	3.3-4.4V，典型 3.8V；Power Consumption 仍为 TBD。	规格 p.3

重要：“RG660MK-EU 模组有 USB 3.2 Gen2”不等于“当前 CPE 外壳上那个 USB 口就是 10Gbps Host”。载板原理图、USB role、PHY/Hub/Type-C 控制器、内核配置和实际 lsusb -t 才是 Demo 的判定依据。

2.2 第一阶段必须实机确认的未知项

- 当前暴露 USB 口是 Host、Device 还是 Dual Role；连接算力棒时能否进入 Host。
- 实际 USB 速率是否显示 480M、5000M 或 10000M。
- OS/Kernel/CPU ABI/libc/root 权限/init 系统/可写持久分区。

- 是否允许安装或加载 HailoRT 需要的用户态组件与内核模块；是否有 Secure Boot/模块签名/只读 rootfs 限制。
- DB9 的电气标准和 AT/Console/DIAG 映射。
- 当前载板是否额外引出第二 USB、PCIe、PCM 等接口。

3. USB 算力棒方案总体架构


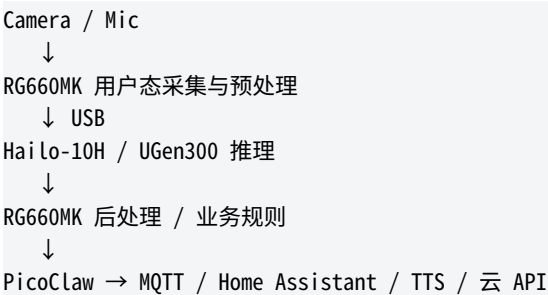


图 1 RG660MK-EU + USB 算力棒的一体化 AI CPE 推荐架构

架构原则：RG660MK-EU 仍然是唯一 CPE 主控和 Agent 主体；USB 算力棒只是推理协处理器。算力棒失效时，PicoClaw 可降级到云 API 或无 AI 模式，但 5G、RJ45、DHCP、DNS、NAT 必须继续工作。

3.1 数据流



3.2 单 USB 口的资源约束

- 如果当前载板只有一个 Host 口，需要使用有源 USB 3.x Hub。
- Camera 数据先进入 RG660MK，再把张量/帧送入 NPU；同一 Hub 上会形成“Camera→Host”和“Host→NPU”的两段 USB 流量。
- USB Audio 带宽较低，但 Camera + NPU 并发会同时占用 USB、内存带宽和 CPU 预处理/后处理资源。
- 如果只有 USB 2.0，原则上不立即否定，但只能从低分辨率/低帧率开始，且 UGen300 的 10Gbps 接口优势无法发挥；此时 RJ45 外置 AI Host 可能更合理。

4. 算力棒选型与边界

4.1 首选候选：ASUS UGen300 USB AI Accelerator 8GB

属性	官方公开规格
芯片	Hailo-10H
接口	USB 3.1 Gen2 Type-C, 10Gbps
AI 算力	40 TOPS INT4 / 20 TOPS INT8
内存	8GB LPDDR4
典型功耗	2.5W
Host 架构	x86 / ARM
OS	Linux / Windows / Android（具体发布状态以官方驱动为准）
框架	Keras / TensorFlow / TensorFlow Lite / PyTorch / ONNX
模型类别	Vision / GenAI；官方材料宣称提供预训练模型/Model Zoo

来源：ASUS UGen300 官方 Tech Specs 与 Hailo-10H 官方产品页面（见参考资料 [3][4]）。上述是算力棒自身能力，不代表 RG660MK-EU 当前固件已经兼容。

兼容性警告：“支持 ARM Linux” 仅说明厂商支持某些 ARM Linux 主机，不等价于“支持任意嵌入式 Linux”。RG660MK-EU 的 kernel、glibc、root、USB host、内核模块加载能力必须通过 Gate 验证。

4.2 为什么不把 Coral USB 作为主方案

- Coral/Edge TPU 生态更偏 TFLite/Edge TPU 编译模型，适合轻量视觉，模型迁移边界更窄。
- SG560D 归档包含 YOLO/QNN/HTP、MediaPipe、Paraformer、Qwen Vision 等多类工作负载；Hailo-10H 类方案的通用模型/GenAI 定位与 8GB 专用内存更符合扩展需求。
- 但 Hailo 也不是“任何 PyTorch 模型即插即用”；仍需要模型转换/编译、算子支持验证、量化与精度回归。

4.3 Jetson 的新定位

Fallback：Jetson Orin Nano/工业 AI Box 保留为回退方案：当 USB 口不是 Host/SuperSpeed、HailoRT 无法安装、模型无法编译、Camera+NPU 并发破坏 CPE 稳定性，或需要复杂 CUDA/TensorRT/多模型开发时，改走 RJ45 外置主机。

5. SG560D 功能迁移矩阵

功能	SG560D 状态	RG660MK-EU + USB 算力棒路线	优先级
PicoClaw 文本对话	已有工作区/历史能力	RG660MK ARM64/Linux 原生部署；配置逐项迁移	P0
V2.2 APK 本地意图/ASR 容错	APK 可安装	抽取规则/词典/协议，重写为	P1

功能	SG560D 状态	RG660MK-EU + USB 算力棒路线	优先级
		PicoClaw tool/service; 不以 APK 兼容为目标	
连续对话	基本 PASS	PicoClaw + VAD/KWS/ASR/TTS; 轻量处理在 RG, 推理优先 NPU 或云	P1
本地 TTS	历史有失败	USB Audio + Linux TTS; 可用云 TTS fallback; NPU 不承担音频输出	P1
Paraformer/VAD/KWS	有归档	逐模型评估 Hailo 编译; 不兼容则 CPU/云/RJ45 fallback	P1
摄像头	SG Camera 路线	UVC; 先 720p/MJPEG, 再 1080p; Camera 采集在 RG 用户态	P1
C++ 人脸→MQTT→灯	端到端 PASS	保留 MQTT topic/payload/3 秒轮询/2 轮冷却; 人脸模型迁到 Hailo	P1
YOLO/QNN/HTP	Qualcomm 相关	QNN/HTP runtime 不复用; 优先从 ONNX/原始模型进入 Hailo 编译链	P1
Qwen Vision	旧 Key 有失败	云 API 为主; 小型 VLM 可作为 Hailo-10H 专项研究, 不纳入首个验收	P2
MediaPipe	有归档	评估可转换子模型; 图/几何后处理仍由 CPU 执行	P2
Immich	网络服务	REST/API/上传逻辑直接迁移	P1
涂鸦 MQTT	网络协议	直接迁移, 密钥外置	P0
Home Assistant	网络协议	MQTT/REST 直接迁移	P0
Matter/ChipTool	平台相关	Linux ARM64 重编译; BLE/Thread 需外设; 后置	P2
微信 Channel	有归档	与当前 PicoClaw channel schema 对齐后启用	P2

6. USB / Camera / Audio / BLE 外设设计

6.1 有源 USB Hub

- 建议 USB 3.2 Gen2/10Gbps 级有源 Hub, 至少 4 口, 独立 12V 或 USB-PD 供电。
- 不要让 RG660MK-EU 载板同时为算力棒、Camera、Speaker/Mic、BLE 供电。Quectel Preliminary 规格中模组功耗项仍为 TBD, 因此不能按模组文档推导可给外设的 USB 电源余量。
- Hub 必须逐级接入验证: Hub → NPU → Camera → Audio → BLE。每一步都做 dmesg、lsusb -t 和 CPE 稳定性测试。

6.2 Camera

- 首选标准 UVC、支持 MJPEG 的摄像头, 以降低 USB 带宽和 CPU 解码压力。
- 第一阶段建议 720p@15/30fps; 通过后再升到 1080p。
- 视觉链路分层计时: 采集→解码/resize→NPU 输入→推理→后处理→MQTT, 避免只看 NPU FPS。

6.3 USB Audio

- 首选 USB Audio Class 设备，Mic + Speaker 一体，避免第一阶段设计 PCM Codec。
- 要求 aplay -l / arecord -l 可枚举；连续 20 轮 ASR→PicoClaw→TTS 不丢设备。
- 音频失败只降级语音功能，不得触发网络服务重启。

6.4 BLE / Matter

可选：RG660MK-EU 规格并未把 Bluetooth 作为明确接口能力，因此 BLE 不应由“Wi-Fi 8*”推导。需要 Matter/BLE 时优先 USB BLE Dongle，并后置到 CPE + NPU + Camera + Audio 已稳定之后。

6.5 DB9 / UART

- DB9 只说明物理连接器，不证明内部是 RS232 电平。
- 必须确认 TX/RX/GND、AT/Console/DIAG/GNSS 映射、RS232 电压还是 1.8/3.3V TTL、波特率和流控。
- 真 RS232 可用 FTDI USB-RS232；TTL↔RS232 才需要 MAX3232。

7. 软件架构与进程边界

进程/服务	职责	优先级/隔离要求
cpe/network	蜂窝、LAN、DHCP/DNS/NAT/Firewall	最高；AI 不得修改
picoclaw	对话、tools、channel、业务编排	高
ai-runtime	HailoRT/设备管理/模型生命周期	中；失败可重启/禁用
capture	V4L2/ALSA 采集	中
ai-service	vision/asr/kws 等统一 API	中
mqtt-bridge	Home Assistant/涂鸦/事件	中
cloud-fallback	LLM/VLM/TTS/ASR 备用	低-中
metrics	CPU/内存/温度/USB/丢包/延迟	独立只读

7.1 推荐目录

```
/home/picoclaw/ 或持久分区：
picoclaw/
ai_runtime/
ai_models/
services/
  vision/
  audio/
  mqtt/
config/
logs/
tests/
rollback/
```


7.2 统一 AI 服务接口

```
GET /health
POST /vision/detect
POST /vision/face
POST /audio/asr
POST /audio/kws
POST /tts
GET /metrics
```

- 所有请求必须有 request_id、timeout、明确错误码。
- 模型不可用时返回“能力不可用”，不能阻塞 PicoClaw 主循环。
- MQTT 发布必须幂等；灯控闭环保持历史 3 秒轮询与 2 轮冷却作为初始基线。

8. 模型迁移与 QNN/HTP 替代路线

原则：SG560D 上的 Qualcomm QNN/HTP runtime、DSP/HTP 二进制、APK JNI 产物不视为可直接迁移。目标是找回原始模型或 ONNX/TFLite 等可移植表示，并重建算力棒编译链。

8.1 每个模型的迁移证据链

1. 确认原始框架和输入输出：PyTorch/ONNX/TFLite/QNN DLC/其他。
2. 优先找到 ONNX 或原始训练/导出脚本；如果只有 QNN 产物，记录为高风险，不承诺可逆。
3. 准备固定校准/验证数据集。
4. 完成 Hailo Dataflow Compiler / Model Zoo 适配或厂商推荐的转换流程。
5. 比较 SG560D 基线与新模型：准确率、mAP、关键点误差、WER、延迟、FPS、CPU 占用。
6. 保存编译器版本、模型哈希、量化参数和输出 artifact 的 SHA-256。

8.2 预/后处理位置

- 图像 resize、色彩转换、归一化、NMS、MediaPipe 几何逻辑等可能仍消耗 RG660MK CPU。
- 因此“算力棒 40 TOPS”并不能消除主机 CPU 瓶颈；必须记录端到端延迟。
- 若 1080p 解码/预处理导致 CPE 抖动，优先降分辨率/帧率，随后考虑 RJ45 外置 AI Host，而不是牺牲 CPE 稳定。

9. 分阶段 Gate 实施计划




图 2 USB 算力棒路线 Gate 与回退决策

Gate 0：只读盘点与 USB 资格确认

- 确认 SRC_ROOT、旧 SG560D 归档哈希和历史证据。
- 确认 RG660MK OS/Kernel/arch/libc/root/init/持久分区。
- 确认当前载板 USB role；执行 `lsusb -t`，记录 480M/5000M/10000M。

- 确认 DB9 映射与电平；禁止向未知串口发送 AT。
- 输出 GATE0_REPORT.md。

Gate 1：CPE 基线

- SIM/注册/数据上下文 PASS。
- RG 本机 DNS/HTTPS PASS。
- RJ45 DHCP/DNS/NAT PASS。
- 30 分钟 ping/路由/CPU/内存/温度日志。
- AI 服务尚未启用。

Gate 2：PicoClaw 基线

- 固定版本、ARM64 兼容、配置可回滚。
- 最小文本请求 PASS。
- 服务化启动但不得阻塞 CPE。
- 30 分钟稳定且网络基线无回归。

Gate 3：Hailo/UGen300 兼容性

- 算力棒 USB 枚举 PASS。
- HailoRT/官方 Runtime 安装 PASS。
- 设备识别、固件/版本读取 PASS。
- 官方样例模型推理 PASS。
- 停止/拔出 NPU 后 CPE 不异常。

Gate 4：SG560D 模型迁移

- 先人脸/轻量 YOLO，再 VAD/KWS，再 ASR/其他。
- 每个模型有固定输入集、精度/性能对比和回滚。
- 不允许“文件存在”代替端到端 PASS。

Gate 5：多外设并发

- 有源 Hub + NPU + Camera + Audio；BLE 最后。
- Camera 连续采集 30 分钟。
- AI 推理+MQTT+TTS 并发。
- CPE 丢包/延迟/CPU/温度/USB 错误不得显著恶化。

Gate 6：完整 Demo

- Camera→人脸/YOLO→MQTT→Home Assistant→灯。
- PicoClaw 返回文字状态并可选 USB Speaker 播报。
- 保留约 3 秒轮询、2 轮冷却作为历史行为基线。
- 异常断网、NPU 拔出、Camera 拔出、重启后均可恢复。

10. 测试与验收设计

测试项	方法	PASS 标准
USB Host	lsusb -t / dmesg	算力棒枚举稳定；记录实际速率；无反复 reset/disconnect
NPU Runtime	官方样例/设备工具	识别成功；样例推理重复 100 次无错误
Camera	v4l2-ctl/采集脚本	30min 连续采集；无掉设备；帧率有日志
Audio	arecord/aplay	20 轮录音+播报；无设备丢失
视觉	固定图片/视频集	精度对比；端到端 p50/p95 延迟；FPS
ASR/KWS	固定语音集	WER/命中率/延迟；环境噪声样本
MQTT/HA	灯控闭环	topic/payload/重连/幂等；3 秒轮询/2 轮冷却
CPE	ping/DNS/HTTPS/iperf 可选	AI 开启前后对比；无异常断线；DHCP/NAT 正常
资源	top/proc/thermal/dmesg	CPU、内存、温度、USB 错误、OOM 均有日志
故障注入	拔 NPU/Camera/断网/重启	AI 降级但 CPE 存活；恢复路径明确

11. 风险与回退设计

风险	严重度	表现	缓解/回退
R1 USB 非 Host 或仅 USB2	高	算力棒无法使用或性能受限	Gate 0 即判定；回退 RJ45 外部 AI Host
R2 HailoRT 无法安装	高	设备不可驱动	不改系统核心；回退云/Jetson
R3 模型算子不支持	高	QNN/ONNX 无法编译	替换网络/重新导出/云 API/Jetson
R4 CPU 预处理瓶颈	中-高	NPU 快但端到端慢	MJPEG/降分辨率/优化预处理/外置 AI
R5 USB 供电/Hub 不稳	中-高	随机掉 Camera/NPU	有源 Hub；逐设备压测；更换电源/线材
R6 AI 进程影响 CPE	高	5G/RJ45 掉线	cgroup/优先级/资源限制；AI 一键禁用
R7 量化精度下降	中	人脸/YOLO 误判	固定数据集校准；A/B；保留云/CPU fallback
R8 Preliminary 规格变化	中	接口/功能与量产版变化	锁定文档版本，所有硬件结论以样机/最终规格复核

11.1 一键降级要求

```
stop_ai.sh      # 停止 Camera / Hailo / ASR / TTS / 视觉服务
stop_picoclaw.sh # 可选停止 Agent
# 任何脚本不得停止蜂窝、DHCP、DNS、NAT、Firewall 核心服务
```

12. 采购配件清单

12.1 第一优先级：算力棒方案核心件

配件	数量	推荐规格/候选	用途	采购说明
USB AI 算力棒	1	ASUS UGen300 USB AI Accelerator 8GB / Hailo-10H	核心推理协处理器	建议 Gate 0 确认 USB Host/SuperSpeed 后采购；ASUS 台湾官方价 NT\$6,890 可作区域参考，大陆价格以渠道询价为准。
有源 USB Hub	1	USB 3.2 Gen2/10Gbps, 至少 4 口，独立供电	NPU+Camera+Audio+BLE 扩展	必须有源；避免依赖 RG 供电。
高速 USB 数据线	1-2	支持 10Gbps, Type-C/Type-A 依据载板	连接 UGen300/Hub	禁止仅充电线；优先短线。
UVC Camera	1	支持 MJPEG; 720p/1080p30	视觉 Demo	先 720p Gate, 再升 1080p。
USB Audio	1	UAC; Mic+Speaker	ASR/TTS	比第一阶段做 PCM Codec 风险低。
USB-RS232	1	FTDI 芯片、DB9	AT/Console 调试	只有确认是真 RS232 后直连。

12.2 可选/后置件

配件	数量	推荐规格	用途	说明
USB BLE Dongle	1	Linux 驱动成熟型号	Matter/BLE	P2; 不由 Wi-Fi 8 推导蓝牙已内置
MAX3232 转换板	1	3.3V/5V 兼容	TTL↔RS232	仅当 DB9/排针侧确认需要电平转换
备用 Jetson/AI Box	0-1	Orin Nano/工业 AI 主机	Fallback	不作为首购；只有 Gate 失败时再采购/调用现有设备
USB 功率计	1	支持 USB-C/PD/电流统计	供电调试	推荐，用于定位 Hub/NPU 掉线
散热/风扇	按需	载板/机壳适配	长稳测试	依据温度日志决定

中国国内采购：Hailo 官方“Greater China”销售页面已列出可覆盖 Hailo-10H 的区域分销渠道 AIT；ASUS UGen300 在台湾 ASUS eStore 有公开售价。中国大陆具体含税/交期/保修价格建议向 ASUS 商用渠道或 Hailo Greater China 分销商询价，并要求明确 Linux ARM 驱动/技术支持范围。

12.3 暂不采购

- PCIe NPU / M.2 AI 卡：虽然 RG660MK-EU 模组有 PCIe 4.0/3.0，但当前载板是否引出、RC/EP、Lane、驱动均未确认。
- PCM Codec/功放板：Demo 先 USB Audio。

- 多摄像头 Hub/高端相机：单摄像头闭环稳定后再扩展。
- 自研载板：等 USB 算力棒 PoC、功耗、热、模型兼容全部闭环后再进入产品化。

13. 给 Claude Code 的执行总指令

执行原则：不要重新 clone/推翻旧工程；先只读盘点，再 CPE，再 PicoClaw，再算力棒。任何未知 USB role、串口电平、分区、启动机制或内核模块限制都必须停下来记录 BLOCKED，不能猜。

你现在执行 RG660MK-EU AI CPE USB 算力棒迁移项目。

目标：

- 1) 保持 RG660MK-EU 5G CPE 完整稳定；
- 2) 在 RG 上部署可回滚 PicoClaw；
- 3) 优先验证 USB Host/SuperSpeed；
- 4) 在兼容条件满足后接入 Hailo-10H/ASUS UGen300 类 USB AI Accelerator；
- 5) 迁移 SG560D 的 MQTT/Home Assistant、Camera、人脸/YOLO、ASR/VAD/KWS/TTS 等能力；
- 6) QNN/HTP 二进制不得当作可直接复用。

禁止：

- dd/mkfs/fdisk/parted/刷机/恢复出厂；
- 未确认电平前接线或向未知串口发 AT；
- 修改 CPE 核心网络服务来“适配 AI”；
- 把 API Key/Token/密码写进日志；
- 购买/接入 NPU 前跳过 USB Host/Speed/Kernel 兼容性 Gate。

每个 Gate 必须输出：

命令、原始日志、证据、PASS/FAIL/BLOCKED、对 CPE 影响、回滚方法、下一 Gate 是否允许。

13.1 Gate 0 起始命令

```
echo '===== SYSTEM ====='
uname -a
uname -m
cat /etc/os-release 2>/dev/null || true
getconf LONG_BIT 2>/dev/null || true
ldd --version 2>&1 | head -n 3 || true

echo '===== USB ====='
lsusb
lsusb -t
dmesg --ctime | tail -n 200

echo '===== NETWORK ====='
ip -br link
ip -br addr
ip route
ip rule

echo '===== STORAGE / INIT ====='
df -hT
mount
ps -p 1 -o pid,comm,args
```

```
echo '==== RESOURCES ===='
cat /proc/meminfo | head -n 20
cat /proc/cpuinfo | head -n 80
```

13.2 USB 算力棒采购前的硬门槛

- 必须能证明当前外露 USB 可作为 Host。
- 优先看到 5000M/10000M；如果只有 480M，要在采购报告中明确“性能风险”。
- 必须知道 kernel 版本、ARM64 ABI、libc、root/模块加载能力。
- 必须形成 HailoRT 兼容性调查结论；如果厂商只支持不同 kernel/发行版，不得盲买。

14. 最终结论

本版推荐的首选产品架构是：**RG660MK-EU = 5G CPE + PicoClaw + 业务编排；USB Hailo-10H/UGen300 = 本地 AI 推理协处理器。**

- 该路线比“RG660MK + RJ45 + Jetson”更接近真正一体化 AI CPE，体积、功耗和产品边界更清晰。
- 它的最大不确定性不是 TOPS，而是 RG660MK 当前固件对第三方 USB AI Runtime/驱动的兼容性，以及 Camera/NPU 共用 USB 时的端到端资源压力。
- 因此项目成功关键是把“USB Host/Speed → Runtime → 样例推理 → 模型迁移 → 并发 CPE 回归”做成硬 Gate，而不是先采购后调试。
- Jetson 保留为工程回退，不作为默认 BOM。

15. 参考资料

[1] Quectel. Quectel RG660MK-EU 5G Module Specification V1.0.1 Preliminary, 2026-08-19. 重点： p.1 CPU/5G； p.2 频段、数据率与接口； p.3 Audio/Power/Wi-Fi 8*。

[2] 《RG660MK AI CPE Demo： PicoClaw 部署与 SG560D AI Assistant 迁移设计》 V1.0, 2026-08-19. 重点： p.9-11 迁移矩阵、USB/RS232/RJ45/NPU 设计。

[3] ASUS. UGen300 USB AI Accelerator 8GB - Tech Specs.
<https://www.asus.com/us/motherboards-components/ai-accelerator/ugen/ugen300-usb-8g/techspec/> （访问： 2026-08-20）

[4] Hailo. Hailo-10H AI Accelerator. <https://hailo.ai/products/ai-accelerators/hailo-10h-ai-accelerator/> （访问： 2026-08-20）

[5] Hailo. Distributors - Greater China. <https://hailo.ai/products/shop/region/greater-china/> （访问： 2026-08-20）

[6] ASUS Taiwan. UGen300 USB AI Accelerator 8GB Tech Specs / eStore reference price NT\$6,890.
<https://www.asus.com/tw/motherboards-components/ai-accelerator/ugen/ugen300-usb-8g/techspec/> （访问： 2026-08-20）

版本控制： 本文按 RG660MK-EU V1.0.1 Preliminary 编制。若 Quectel 发布正式版 Specification/Hardware Design 或当前载板原理图，应首先更新“规格基线”和 Gate 0，再决定是否修改 USB/PCIe/音频方案。