

RG660MK 智能音箱语音助手 · 阶段工作总结

- 报告日期：2026-09-21
- 工作周期：2026-09-14 ~ 2026-09-20
- 分支：fix/voice-assistant-router-turn-timeout (8 个提交, 领先 main)
- 代码量：22 个文件, +2864 / -101 行 (其中语音助手模块 17 个文件, +2629 / -101)
- 设备：RG660MK CPE (OpenWrt / aarch64), 已部署并实测

一、结论摘要

本轮工作把语音助手从「能跑通」推到关键路径可靠：修复了三个会导致用户听到错误答复的缺陷，把实时行情从「我查不了」变成 0.3 秒正确播报，并按设计文档落地了新疆口音专项的 P0/P1 逻辑层。

已完成且有设备实测证据的：分层路由与轮次隔离、实时行情处理器、「拒绝不得成为终答」机制、Hermes 输出清洗、端到端延迟优化、口音纠错逻辑层、唤醒可用性修复。

尚未完成的是口音识别率的量化验收——这部分必须在真机上用真实新疆口音录音完成，离线测试无法替代。详见第四节。

二、改进了什么

2.1 分层路由与轮次隔离 (09-14, 提交 491ee3d)

问题：多轮对话中上一轮的答复会串到下一轮；慢查询没有任何反馈，用户不知道设备是否还在工作。

做法：

- `dispatch()` 按设计文档 §2.1 分层：设备控制 → 天气 → 行情 → 日期时间 → 本地计算器 → LLM 函数调用兜底 → Hermes；
- 每一轮分配独立 `turn_id`，过期轮次的回复直接丢弃，不再污染新一轮；
- 30/60 秒双超时：30 秒播一次「请稍等。」（不打断后台），60 秒才放弃。

2.2 实时行情：从「我查不了」到 0.3 秒正确播报 (09-18)

问题现象：问「请查看移远通信的收盘价」，答「我查不了股市行情」。

根因是三个缺陷叠加，缺一不可：

1. 主因：`dispatch()` 把模型的回绝文本当成最终答案直接播报（1.5 秒返回），Hermes 从未被调用——而实测 Hermes 本身能答对，耗时约 29 秒。
2. 设计文档 §2.1 的 L1「实时联网」层只实现了天气，行情没有处理器，只能落到 L2。
3. 即使修好路由也仍然是坏的：`hermes_ask()` 返回的 `stdout` 开头是英文推理框（`└ Reasoning ┘`），而 `speak()` 先截断 120 字符再做中文占比过滤，实测中文占比 0.03 被判定为乱码，用户会听到「回复内容暂时无法播报」。

做法：

- 新增 L1 行情处理器：腾讯 `qt.gtimg.cn` 为主、新浪 `hq.sinajs.cn` 为备、`smartbox.gtimg.cn` 做名称检索；
- `resolve_symbol()` 三级解析：显式代码 → 本地别名表（含已观察到的 ASR 形近误听「亿元通信 / 一元通信」）→ 联网检索；
- 按行情时间戳区分「收盘」与「最新价」，名称一律用接口返回的正式名，避免把误听的名字念出来；

- 「拒绝不得成为终答」两道闸：is_capability_refusal() 识别回绝措辞，needs_live_data() 拦截「实时数据类问题却不带工具作答」（编造数字比回绝更糟）——两者都转 Hermes；
- 新增 extract_hermes_answer(), 从 stdout 末尾取连续中文段落，剥掉推理框与 session_id；
- LLM_OR_HERMES 移出 7 秒快速失败集合（它现在会升级到 Hermes，实测约 29 秒），改走 30/60 双超时。

效果（设备实测，2026-09-18 收盘后）：

提问	结果	耗时
请查看移远通信的收盘价	移远通信今天收盘72.54元，跌1.12元，跌幅百分之1.52。	0.33s
移远通信今天股价多少	同上	0.28s
上证指数今天收盘多少	上证指数今天收盘3911.87元，涨36.27元，涨幅百分之0.94。	0.32s
亿元通信股价（实测误听）	正确解析到移远通信 72.54	0.32s
今天美元兑人民币汇率多少	回绝被拦截，转 Hermes	1.74s 后升级
今天有什么新闻 / 92号汽油多少钱一升	同上，均不再播报回绝	—

Hermes 输出清洗实测：raw=1970 字符 → answer=74 字符，中文占比 0.59，无推理框与 session_id 残留，可正常播报。

2.3 端到端延迟优化（09-18，随 af9af36 固化）

项目	改进前	改进后
固定提示音（「在呢，请说」等）	每次联网合成	本地缓存 + 部署时预热，预热后零网络
whisper 音频上下文 -ac	固定 1500	按音频时长动态计算（保留一秒余量）
ASR 单次转写	无有效上限（90s）	8 秒硬上限，失败返回空
唤醒收尾等待 end_sil_ms	2000ms	800ms
天气查询超时	8s / 10s	2s / 4s
灯控超时	30s	6s
超时预算	一刀切	只有确定不升级的意图才享受 7 秒快速失败

另新增 [LATENCY] 日志（asr_s / tts_ready_s），后续可量化复核。

2.4 新疆口音识别 P0/P1 逻辑层（09-20，提交 cabb03b）

依据《RG660MK 智能音箱新疆口音识别优化设计 V1.0》，落地口音专项的离线逻辑层：

- 新增 accent_correct.py（275 行，纯 stdlib）：内置业务词表拼音映射（设备端不依赖 pypinyin）；口音模糊音节等价类覆盖翘舌 / 平舌合并、前后鼻音合并、n/l 合并、f/h 相混、r 弱化；correct_command() 做音节级编辑距离 ≤1 的受限纠错，只把疑似口音误识别的控制类短句拉回已知命令，且返回原文 / 纠正 / 规则 / 距离，可解释可回滚；

- 集成位置：口音纠错挂在 `classify()` 的最末兜底位——任何标准普通话意图先命中就直接返回，绝不进入纠错，保护基线不退化；
- 新疆地名：CITIES 与天气链路补入乌鲁木齐、喀什、伊犁、克拉玛依、吐鲁番等 14 个地名。

设备端实测抓取：

```
[ACCENT] '打开客厅灯' -> '打开客厅灯' (dist=0) → DEVICE_CONTROL / control_bulb / 0
on
[ACCENT] '关闭客厅灯' -> '关闭客厅灯' (dist=0) → control_bulb / off
[ACCENT] '打开卧市灯' -> '打开卧室灯' (dist=0) → control_bulb / on
打开窗连 -> 打开窗帘（文本纠对；当前无窗帘工具，按预期走 LLM 兜底）
乌鲁木齐/喀什/伊犁/克拉玛依/吐鲁番/库尔勒/哈密 → WEATHER + 城市提取正确
```

2.5 唤醒可用性修复（09-20 晚，提交 32e75b6 + d5e9de4）

问题：用户实测「你好小皮」多次失败或答非所问。
定位：抓取真实录音做同一音频 A/B 对比，量化出 `whisper --prompt` 热词偏置是固定成本 +2.2~2.5 秒（约为基线 2 倍，与音频长度无关），且在真实音频上判定为负面：

模式	「你好小皮」转写结果	影响
无 prompt	你好下题	接近唤醒词，可正常唤醒
全量热词 prompt	阿梅，鲁，河田	被热词表（乌鲁木齐 / 和田等）劫持 → 误落天气 → 答「你想查哪个城市」

修正：热词 prompt 改为默认关闭（机制保留，`VOICE_ASR_PROMPT=1` 一键启用）；唤醒 / 待机路径停用 prompt，命令路径保留机制待真机 A/B；`strip_wake()`
全量收敛循环唤醒词，纯唤醒呼叫回「在呢 / 我在听」，不再把 你好下皮×75
这类循环输出当命令送后端；唤醒词变体补入实测到的「下题」。

三、验证情况

验证项	结果
本机 pytest (tests/)	38 passed / 83 subtests passed, 0 回归
验收脚本 (test_acceptance.py)	27 / 27 ALL GREEN
accent_correct.py selftest	12 PASS / 0 FAIL
设备端 accent_selftest_device.py	37 项断言 ALL PASS
设备部署	/etc/init.d/voice_assistant restart 正常, rec=plughw:2,0 play=plughw:2,0 vad=True

回归套件由 12 项扩展到 38 项。测试用 `tests/fixtures/hermes_stdout_sample.txt` 保存了真实 Hermes stdout 样本，回绝措辞用例取自 2026-09-18 实测抓到的 5 条真实语料。

四、还差什么

4.1 真机验收缺口（阻塞量化目标，必须用真实录音完成）

这是本阶段最主要的未完成项——离线逻辑层已证明可靠，但识别率的量化改善没有证明：

1. CER / 命令准确率的真机验收：需按设计 §7 采集新疆口音开发集 / 验收集（各 300-500 句）真实录音，跑基线 vs 优化后对比。当前编辑距离阈值与混淆规则均为待真机混淆矩阵校准的初值（设计 §6.3 明确要求「从真实测试集统计，不凭印象定死」）。
2. whisper --prompt 的真实增益：命令路径的热词偏置目前默认关闭，需真实口音录音 A/B 通过后才能启用。
3. VAD 首尾完整率：设计目标 ≥98%，需真人近讲 / 远讲录音统计。
4. 端到端 P95 时延：设计 §9 要求 --prompt 不显著增加时延，待真机测。

4.2 待查与未复测

5. 真人语音端到端未复测：09-18 行情修复的验证全部是「文本 → 真实服务调用」，唤醒 → ASR → 播报的完整链路本轮未复测。
6. 个别转写为空的成因未查清：上机时出现过两次唤醒转写为空 ''，现场抓录分析中。
7. 解码循环率未统计：whisper base 在少量音频上会陷入重复循环（合成音频「打开卧室灯」无 prompt 时输出 打开握时登×36，耗时 6.8s；另有样本循环且截断在半个 UTF-8 字符上触发 UnicodeDecodeError）。当前 transcribe() 捕获后返回空、降级为「请再说一下，我没听清」，安全但体验差；真实录音下的循环率需统计。

4.3 已知问题（非本轮引入）

8. whisper 延迟数据不一致：README 记录「base ~9.6s/5s 片段」，而 09-20 上机实测为 2.43~2.58s，两者存在量级差异，需核实并统一文档口径。
9. 人脸检测无专用模型：face_detect=null，用 pose 关键点（鼻子+眼睛）近似判断人脸可见性。
10. 坐姿检测个别发音被完全漏听：转成「嗯」或空，属语音识别固有问题。
11. YOLO 人计数偶有误检（2 人 vs 1 人），已从播报中移除计数规避。

4.4 条件触发项

12. P2 模型适配：仅当真机验收集出现大量「音频完整但声学识别系统性近音错误」时，才进入设计 §7.2 的 Adapter/LoRA 或供应商自定义声学模型。P0/P1 逻辑层已备好，可先上真机收数据。
13. 实时问答的答案质量：本轮只解决「不再播报回绝」。汇率类问题的答案质量取决于 Hermes 自身选源——实测其返回 Frankfurter 的「昨日」参考价并自述为参考价，该选源问题未改进。

4.5 工程收尾

14. 8 个提交已推送至 origin/fix/voice-assistant-router-turn-timeout，但尚未合并到 main。
15. 工作区有较多未跟踪文件（reports/、docs/ 下的报告与 PDF 等），未纳入版本管理。

五、部署与回滚

设备路径：主程序 /data/ai_cpe/voice_assistant.py，口音模块 /data/ai_cpe/accent_correct.py。

回滚（设备执行）：

```
# 回滚到口音优化之前（Sep16-18 版）
ssh root@192.168.1.1 "cp /data/ai_cpe/voice_assistant.py.bak_20260920_preaccent \
/data/ai_cpe/voice_assistant.py && /etc/init.d/voice_assistant restart"
```

测试时实时看日志：

```
ssh root@192.168.1.1 "logread -f" | grep -iE "ACCENT|WAKE|ASR_TEXT|listen|tool"
```

测试建议：① 唤醒速度（「小皮」→「在呢」）；② 口音读法的灯类命令（关注 [ACCENT] 行）；③ 标准普通话回归（灯 / 时间 / 天气）；④ 「乌鲁木齐今天天气怎么样」；⑤ 若「请再说一下」偏多，记录具体话术样本（可能是解码循环）。

附录：本分支提交清单

提交	日期	说明
491ee3d	09-14	分层路由 + turn_id 隔离 + 30/60 秒双超时
3229c3e	09-16	音频与服务故障修复；归档 09-16 诊断
cabb03b	09-20	新疆口音识别优化 P0/P1 逻辑层
af9af36	09-20	固化 Sep16-18 设备端已验证改动（实时行情 / 拒绝即终答 / TTS 缓存 / ASR 超时）
c12de41	09-20	合并口音优化与设备已验证版本
32e75b6	09-20	唤醒 / 待机转写停用热词 prompt
33a3fa2	09-20	设计 V1.0 入库 + 上机部署与自测记录
d5e9de4	09-20	唤醒可用性修复（prompt 默认关闭 + strip_wake 全量收敛 + 下题变体）

相关文档：README.md、修复与验证记录_20260916.md（第四轮）、新疆口音优化_测试报告_20260920.md、上机部署与自测记录_20260920.md、优化与测试结果说明.md。